UNIVERSIDADE FEDERAL DO TOCANTINS

Bacharelado Interdisciplinar em Inteligência Artificial — BIINAR

Eixo II — Projeto Integrador: Inteligência Tributária (Sefin Palmas) | 2026/2

TAREFA DO PROJETO INTEGRADOR

SPRINT 3 — PIPELINE ETL

Coleta automatizada, transformação e análise exploratória

Período: 13/10 a 27/10/2026 | Entrega: Terça-feira, 27/10/2026, até as 23h59 (encerramento do Módulo 5)

Coordenação: Prof. Dr. David Nadler Prata | Apoio: docentes dos módulos âncora do Eixo II

1. Identificação

Projeto	Sistema de Inteligência Tributária — priorização da cobrança da dívida ativa de Palmas-TO (Opção D)
Sprint	SPRINT 3 — PIPELINE ETL (13/10 a 27/10/2026)
Módulo(s) âncora	Módulo 5 — Coleta, Raspagem e Transformação Digital de Dados
Entrega	Terça-feira, 27/10/2026, até as 23h59 (encerramento do Módulo 5)
Modalidade	Em equipe — 5 integrantes (equipes formalizadas na Sprint 0)
Como entregar	Repositório Git da equipe (branch da sprint mesclada) + artefatos em /docs; link enviado à coordenação
Peso	O Projeto Integrador corresponde a 30% da nota final do Eixo II

2. Objetivo da sprint

Fazer o dado fluir sozinho: coleta automatizada via API da Prefeitura de Palmas e Portal de Dados Abertos, pipeline ETL completo com enriquecimento socioeconômico (IBGE) e engenharia de atributos, e o Relatório de Análise Exploratória que revela os padrões da inadimplência.

3. Entregáveis

E1 — Script de coleta automatizada. Coleta via API REST da Prefeitura (autenticação, paginação e rate-limiting tratados) e demais fontes mapeadas — não é aceita base estática do Kaggle. Dados brutos preservados e datados em data/bruto.

E2 — Pipeline ETL funcional de ponta a ponta. Script único (etl_sefin.py) com extração, limpeza documentada, enriquecimento com variáveis socioeconômicas do IBGE, engenharia de atributos (tempo de inadimplência, sazonalidade, faixas de valor) e carga no banco da Sprint 2 — com validações de qualidade e logs de execução.

E3 — Relatório de EDA. Análise exploratória com estatísticas descritivas e visualizações honestas (evolução, composição, distribuição, relação), incluindo o mapa geoespacial de inadimplência por setor urbano de Palmas, cada gráfico com sua frase de leitura.

E4 — Reprodutibilidade. README atualizado: como executar o pipeline do zero, dependências, estrutura de pastas (bruto/limpo/pronto) e divisão de trabalho da equipe nesta sprint.

4. Marcos semanais (cronograma do PI)

Semana	Marco
12/10 a 16/10	Script de coleta via API validado + primeiro lote de dados brutos extraído
19/10 a 23/10	Base limpa e enriquecida com IBGE; engenharia de atributos implementada
26/10 a 27/10	ENTREGA Sprint 3: ETL de ponta a ponta + Relatório de EDA com mapa geoespacial

5. Critérios de avaliação (rubrica)

Critério	O que será observado	Peso
Coleta (E1)	API consumida com robustez e ética; bruto preservado e datado	25%
Pipeline ETL (E2)	Ponta a ponta, com enriquecimento, validações e logs	35%
EDA (E3)	Visualizações corretas e honestas; mapa geoespacial; frases de leitura	25%
Reprodutibilidade (E4)	Reconstrói do zero seguindo só o README	15%

6. Orientações e combinados

- A entrega é por equipe (5 integrantes); a participação individual é conferida pelo histórico de commits, pelos pull requests e pelo diário de bordo.
- As tarefas semanais do Módulo 5 são os degraus desta entrega — quem as fez em dia já tem quase tudo pronto.
- Orientações éticas valem integralmente: robots.txt, delays nas requisições, fontes oficiais e nenhum dado pessoal além do necessário (anonimização antes do armazenamento).
- Ética na coleta e no tratamento, sempre: fontes oficiais, robots.txt respeitado, delays nas requisições, nenhum dado pessoal além do necessário e anonimização antes do armazenamento (LGPD).
- Atrasos: entregas após o prazo recebem desconto de 20% por dia útil, salvo justificativa acordada previamente com a coordenação.

Por que esta sprint importa

O sistema não pode depender de download manual: dados frescos, todo dia, sem clique.

O modelo da Sprint 4 será treinado exatamente sobre a base que este pipeline entrega.