Pipeline ETL da Sprint 3

Descrição das etapas, da coleta à análise exploratória

Projeto Integrador II · Opção D · Inteligência Tributária de Palmas · BIINAR/UFT · 21/10/2026

1. Visão geral do processo

INTRODUÇÃO

O pipeline da Sprint 3 transforma fontes públicas em uma base analítica confiável. Um único comando, python etl_sefin.py, executa todas as etapas. Este relatório descreve cada etapa na ordem em que ela acontece.

DESENVOLVIMENTO

A arquitetura adotada é a de pipes e filtros. Cada filtro recebe dados, devolve dados e não conhece os demais (Garlan; Shaw, 1993). Assim, uma regra de limpeza pode mudar sem afetar o cruzamento territorial.

A separação entre os filtros é verificada automaticamente. Nove contratos do import-linter impedem dependências fora da ordem do fluxo. Essa divisão segue o critério de Parnas (1972): separar o que tende a mudar.

O processo tem quatro grandes fases: extract, transform, load e EDA. Na execução de referência, elas duraram 57 s, 12 s, 140 s e 4 s. O código de saída informa o resultado: 0 para sucesso, 2 para dado inválido, 3 para falha de coleta e 1 para outro erro.

CONCLUSÃO

O processo, portanto, é automático, modular e verificável. As seções seguintes detalham cada filtro e o que ele garante.

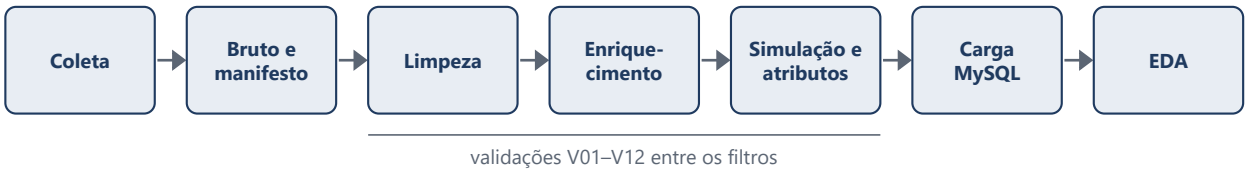


Figura 1 — Sequência de filtros do pipeline da Sprint 3.

2. Coleta automatizada (extract)

INTRODUÇÃO

A coleta busca os dados nas fontes sem nenhum passo manual. Ela consulta sete fontes oficiais e públicas. Na execução de referência, fez 61 requisições sem nenhuma falha.

DESENVOLVIMENTO

As fontes cobrem receita, território, renda e inflação. A arrecadação vem da API da Prefeitura e da extração NUCLEOGOV. As quadras vêm do GeoPalmas, os setores e a renda vêm do IBGE e o IPCA vem do Banco Central.

Toda requisição passa pelo mesmo cliente HTTP. O cliente só aceita TLS 1.2 ou superior, com certificado verificado. Ele também consulta o robots.txt de cada servidor antes do primeiro acesso, como manda a RFC 9309.

O ritmo das requisições protege os servidores públicos. O cliente espera pelo menos um segundo entre dois pedidos ao mesmo host. Falhas transitórias são repetidas com espera exponencial aleatória, e recusas como 403 não são repetidas.

A paginação de cada fonte tem um critério de parada próprio. A API da Prefeitura segue o link next, o WFS do IBGE usa count e startIndex e o Banco Central é percorrido em janelas de dez anos. Em todos os casos, o total recebido precisa igualar o total anunciado.

A recusa do portal NUCLEOGOV foi respeitada. O portal responde HTTP 403, e o pipeline não tenta contorná-lo. Por isso, ele usa a extração oficial distribuída pela coordenação, aceita só se o hash conferir.

CONCLUSÃO

A coleta, em síntese, é completa, ética e auditável. Ela entrega à etapa seguinte apenas dados recebidos de forma íntegra.

3. Camada bruta e manifesto

INTRODUÇÃO

A camada bruta guarda os dados exatamente como chegaram. Ela fica em data/bruto e nunca é sobrescrita.

DESENVOLVIMENTO

Cada arquivo recebe um nome datado e padronizado. O padrão é fonte_assunto_AAAA-MM-DD, com sufixo de página ou de versão quando necessário. Conteúdo novo no mesmo dia ganha uma nova versão, e conteúdo repetido é reaproveitado.

O manifesto registra a origem de cada arquivo. Cada linha guarda URL, status HTTP, tamanho e SHA-256. Cada linha também guarda o hash da linha anterior, o que forma uma cadeia verificável.

A cadeia de hashes é conferida antes de toda transformação. Um arquivo trocado ou uma linha apagada interrompe o pipeline (validação V12). Além disso, a transformação lê só a última coleta completa de cada fonte.

CONCLUSÃO

A camada bruta é, portanto, a memória confiável do processo. Qualquer resultado posterior pode ser refeito a partir dela.

4. Limpeza

INTRODUÇÃO

A limpeza transforma cada fonte em uma tabela tipada. Ela grava o resultado em data/limpo.

DESENVOLVIMENTO

Toda linha lida tem um destino registrado. Ela é aceita, rejeitada com motivo ou descartada como duplicata idêntica. A identidade lidos = aceitos + rejeitados + descartados é exigida para

todas as fontes (V02).

As linhas rejeitadas vão para a quarentena. O arquivo quarentena.csv guarda cada rejeição e o seu motivo. Nenhuma linha some sem explicação.

As decisões de limpeza foram registradas uma a uma. São 21 decisões, cada uma com justificativa e efeito medido. Por exemplo, o sigilo do IBGE ("X") vira ausente, nunca zero, e o dinheiro é tratado em centavos inteiros.

A série de receita une duas fontes sem sobreposição. A API da Prefeitura cobre até 2017, e o NUCLEOGOV cobre de 2019 em diante. A troca de fonte fica marcada nos indicadores, para não ser confundida com mudança real.

CONCLUSÃO

A limpeza entrega, assim, dados tipados e contabilizados. Cada transformação aplicada pode ser conferida no registro de decisões.

5. Enriquecimento

INTRODUÇÃO

O enriquecimento acrescenta contexto econômico e territorial aos dados. Ele combina receita, inflação, Censo 2022 e quadras.

DESENVOLVIMENTO

A receita é convertida para valores reais. O IPCA deflaciona cada mês para reais do último mês publicado. O fator usa 10 casas decimais, o mesmo no Python e no banco.

A renda do Censo 2022 é levada até cada setor censitário. Cada setor recebe densidade, logaritmo da renda, escore-z e quintil. Na execução de referência, 660 setores tinham renda e 23 estavam sob sigilo.

Os setores são cruzados com as quadras pela área de interseção. As contagens dos setores são distribuídas às quadras por interpolação areal (Lam, 1983). O cruzamento formou 1.635 pares entre 733 setores e 283 quadras.

CONCLUSÃO

O enriquecimento liga, portanto, a receita ao território. Esse vínculo é a base dos mapas e dos atributos das etapas seguintes.

6. Simulação da inadimplência

INTRODUÇÃO

A inadimplência por imóvel é simulada, porque nenhuma fonte pública a contém. A dívida por contribuinte só existe na base da Sefin, ainda indisponível.

DESENVOLVIMENTO

A simulação usa o território real como base. Ela distribui os 111.252 imóveis tributáveis de Palmas pelos setores urbanos, na proporção dos domicílios. O resultado foram 556.260 créditos de IPTU simulados.

A chance de atraso segue um gradiente de renda. A direção do efeito vem da literatura (Alm et al., 2014). A intensidade, porém, é uma premissa declarada no ADR-003.

O dado simulado é sempre identificado. Todo crédito leva origem_dado = SINTETICO e fica em tabelas próprias. Todo gráfico com esse dado leva a marca SIMULADO.

CONCLUSÃO

A simulação, em suma, permite testar o pipeline completo sem dado pessoal. Seus padrões territoriais, contudo, refletem a premissa, e não um achado.

7. Engenharia de atributos

INTRODUÇÃO

A engenharia de atributos prepara as variáveis do modelo da Sprint 4. Ela gera a base analítica em data/pronto.

DESENVOLVIMENTO

Três atributos foram pedidos pela Sprint 3. O tempo de inadimplência conta os dias entre o vencimento e o pagamento. A sazonalidade usa o mês, o trimestre e o índice sazonal real, e as faixas de valor usam limites legíveis por um gestor.

Cada coluna tem o momento em que fica disponível. O dicionário da base analítica registra esse momento. Isso evita vazamento de informação no modelo (Kaufman et al., 2012).

CONCLUSÃO

Os atributos ficam, assim, prontos e documentados para a modelagem. O dicionário mostra a origem e o uso seguro de cada coluna.

8. Validações de qualidade

INTRODUÇÃO

As validações impedem que dado inválido avance no pipeline. Elas são avaliadas entre os filtros, e não só no final.

DESENVOLVIMENTO

O pipeline tem doze regras impeditivas e cinco informativas. As impeditivas vão de V01 a V12 e as informativas, de I01 a I05. Cada regra mede uma dimensão de qualidade, como completude, unicidade ou integridade (Wang; Strong, 1996).

Uma regra impeditiva reprovada interrompe a execução. Nesse caso, nada é gravado em data/limpo, em data/pronto ou no banco. O pipeline termina com o código de saída 2.

As validações foram testadas também na reprovação. Testes com dados montados à mão provocam cada falha de propósito. Na execução de referência, as 33 avaliações impeditivas foram aprovadas.

CONCLUSÃO

As validações funcionam, portanto, como portões entre as etapas. Só dado aprovado chega às camadas finais e ao banco.

9. Carga no MySQL

INTRODUÇÃO

A carga leva os dados ao banco da Sprint 2. Ela é transacional e idempotente.

DESENVOLVIMENTO

Cada tipo de tabela tem a sua estratégia de carga. O bruto usa inserção que ignora o existente, e as tabelas de estado usam UPSERT. As quadras usam vigência (SCD tipo 2), e os indicadores são substituídos dentro da transação.

Uma execução repetida não duplica dados. Uma falha no meio da carga desfaz a transação inteira. Mesmo assim, o registro da execução fica salvo, com a regra ou o erro que a interrompeu.

Os valores derivados são calculados por views. Um teste diferencial compara cada view com o resultado do Python. A igualdade é exigida ao centavo ou ao dia.

CONCLUSÃO

A carga, em síntese, deixa o banco igual aos arquivos. Na execução de referência, o banco conferiu com os arquivos crédito a crédito.

10. Análise exploratória (EDA)

INTRODUÇÃO

A EDA transforma a base pronta em leitura para o gestor. Ela é gerada por script, a partir dos dados.

DESENVOLVIMENTO

O relatório reúne estatísticas, figuras e frases de leitura. São sete figuras a 150 dpi, com títulos que afirmam o achado. Dois mapas mostram os setores urbanos de Palmas.

Os dados reais trouxeram achados próprios. Entre 2019 e 2025, o ISSQN cresceu 9,5% ao ano acima da inflação, e o IPTU recuou 2,9% ao ano. O IPTU concentra em março 3,53 vezes a média mensal.

A EDA separa o achado da premissa. Os padrões territoriais da inadimplência vêm da simulação. Por isso, eles aparecem marcados e não são apresentados como descoberta.

CONCLUSÃO

A EDA, portanto, comunica resultados com honestidade. Ela também aponta perguntas para a Sprint 4.

11. Reprodutibilidade e quality gates

INTRODUÇÃO

A reprodutibilidade garante que outra pessoa obtenha o mesmo resultado. Ela é verificada a cada rodada dos quality gates.

DESENVOLVIMENTO

A mesma entrada gera os mesmos bytes. Duas transformações do bruto real produziram 17 arquivos idênticos (gate G14). A semente fixa e o formato determinístico dos arquivos garantem esse resultado.

Os quality gates verificam o código entregue. Passaram 749 testes, com cobertura de 99,3% e mutação de 93,7%. O pior P95 das consultas do painel foi de 1,38 s, abaixo do limite de 3 s.

Um gate ainda está reprovado. O G13 exige que os DOIs do catálogo sejam conferidos no Crossref. Essa conferência depende de autorização e ainda não foi feita.

CONCLUSÃO

O processo é, assim, reprodutível e medido. A única pendência de qualidade é bibliográfica, e não de código.

12. Síntese das etapas

Etapa	O que faz	Garantia principal
Coleta	busca sete fontes públicas	TLS, robots.txt, ritmo e total conferido (V01)
Bruto	guarda o dado como chegou	cadeia de hashes do manifesto (V12)
Limpeza	tipa e contabiliza cada fonte	lidos = aceitos + rejeitados + descartados (V02)
Enriquecimento	acrescenta IPCA, Censo e quadras	IPCA contínuo e setores na malha (V07, V08)
Simulação	cria a dívida de IPTU sintética	taxa igual ao alvo ± 0,5 ponto (V10)
Atributos	monta a base analítica	cruzamento sem perda nem multiplicação (V09)
Carga	grava no MySQL da Sprint 2	transação e views conferidas contra o Python
EDA	gera relatório e figuras	marca SIMULADO em todo dado sintético

13. Conclusão

O pipeline da Sprint 3 cumpre o que o enunciado pede. As quatro entregas, da coleta à reprodutibilidade, estão concluídas. Cada etapa tem uma garantia verificável.

Alguns itens ainda dependem da equipe. Faltam a conferência dos DOIs, o painel .pbix, os nomes na divisão de trabalho e a integração da branch na main. Nenhum deles exige nova funcionalidade.

O próximo passo é institucional. A dívida por contribuinte só virá da base da Sefin. Por isso, a Sprint 4 deve começar por um contrato de dados com a Sefin.

Referências

Os DOIs destas obras ainda não foram conferidos no Crossref (pendência P1). Por isso, este documento não os transcreve. As entradas completas ficam em docs/sprint3/REFERENCIAS.md.

ALM, J. et al. Detroit property tax delinquency: social contract in crisis. 2014.

GARLAN, D.; SHAW, M. An introduction to software architecture. 1993.

KAUFMAN, S. et al. Leakage in data mining: formulation, detection, and avoidance. 2012.

LAM, N. S.-N. Spatial interpolation methods: a review. 1983.

PARNAS, D. L. On the criteria to be used in decomposing systems into modules. 1972.

RFC 9309. Robots Exclusion Protocol. IETF, 2022.

WANG, R. Y.; STRONG, D. M. Beyond accuracy: what data quality means to data consumers. 1996.