UNIVERSIDADE FEDERAL DO TOCANTINS

CAMPUS DE PALMAS

CURSO DE BACHARELADO INTERDISCIPLINAR EM INTELIGÊNCIA ARTIFICIAL

Relatório da Sprint 3 — Pipeline ETL

Projeto Integrador, Eixo II (2026/2) · Opção D: Inteligência Tributária de Palmas · Grupo 1 · 27/10/2026

Repositório: github.com/Guilherme-RCM/projeto-integrador-eixoII-GRUPO1-/tree/main/SPRINT-3 · Contribuições: Pulse do repositório

Introdução: o dado confiável como produto de um processo

A qualidade de um dado não é uma propriedade do arquivo, e sim da relação entre o dado e quem precisa usá-lo. Wang e Strong (1996) chegaram a essa conclusão ao perguntar aos próprios consumidores de dados o que eles entendiam por qualidade: a exatidão apareceu ao lado da completude, da atualidade, da consistência e da facilidade de interpretação, porque um número correto, mas incompleto, desatualizado ou impossível de interpretar, continua inútil para quem decide. Por conseguinte, a planilha baixada de um portal público ainda não é informação para a Secretaria da Fazenda de Palmas; ela só passa a sê-lo quando um processo verificável a torna completa, consistente, datada e legível.

A Sprint 3 pedia exatamente esse processo, e a razão de pedi-lo agora está na Sprint 4. O enunciado exigia que o dado chegasse sozinho e íntegro, do portal ao banco e ao relatório: coleta automatizada (E1), um *pipeline* único de limpeza, enriquecimento, validação e carga (E2), uma análise exploratória honesta (E3) e a reprodutibilidade de tudo isso por qualquer integrante (E4). Polyzotis et al. (2018) mostram que, em sistemas de aprendizado de máquina em produção, os defeitos dos dados se propagam em silêncio até o modelo, que aprende com fidelidade aquilo que recebeu, inclusive os erros; desse modo, a base analítica entregue nesta sprint é o alicerce sobre o qual o modelo de priorização da cobrança será treinado, e um alicerce sem verificação comprometeria todo o projeto.

O grupo respondeu ao pedido tratando a confiabilidade como resultado do processo, e não como qualidade presumida da fonte. Vassiliadis (2009) descreve o ETL como uma sequência de etapas com uma área intermediária que isola o dado de origem do dado publicado; Wilson et al. (2017) recomendam guardar o dado bruto sem alterá-lo e separar o bruto do limpo e do pronto; Sandve et al. (2013) tratam a reprodutibilidade como condição para que um resultado computacional possa ser conferido por outra pessoa. Por isso, o *pipeline* foi organizado em filtros independentes, o bruto é datado e encadeado por SHA-256, as validações impeditivas bloqueiam a publicação de qualquer dado reprovado, como propõem Schelter et al. (2018), e duas transformações da mesma entrada produzem os mesmos bytes.

A mesma atitude orientou a honestidade sobre os limites do trabalho. Box (1976) lembra que todo modelo é uma simplificação, e a simplificação só é científica quando é declarada; como nenhuma fonte pública contém a dívida de cada contribuinte, a inadimplência por imóvel foi simulada sobre os setores urbanos reais, com a premissa registrada em decisão de arquitetura (ADR-003) e a marca SIMULADO em cada tabela e gráfico. A seção 4 mostra, entrega por entrega, que problema futuro cada decisão previne e em que literatura ela se apoia; a seção 5 reúne o que ainda depende de dados que o grupo não tem.

1. Integrantes

Integrante	Conta no GitHub	Entregável (divisão de trabalho do README)
Samuel Jacó	`samueljaco591`	E1 — Coleta automatizada
José Guilherme	`josegui04monici-arch`	E2 — Pipeline ETL de ponta a ponta
Guilherme Rocha	`Guilherme-RCM`	E3 — Análise exploratória (EDA)
Kaio Douglas	—	E4 — Reprodutibilidade e organização

Cada integrante responde por um entregável; as atividades de cada um ficam registradas no diário de bordo. A avaliação é da equipe.

2. Links da Sprint 3

Link	O que contém
Pasta da Sprint 3 github.com/Guilherme-RCM/projeto-integrador-eixoII-GRUPO1-/tree/main/SPRINT-3	A entrega da Sprint 3 no repositório da equipe, no mesmo lugar da Sprint 2.
Versão unificada e executável github.com/Guilherme-RCM/projeto-integrador-eixoII-GRUPO1-/tree/main/SPRINT-3/Sprint3_teste	Código, testes, documentos e evidências dos quatro entregáveis funcionando juntos. É a versão para avaliar e executar; o *README* explica como rodar.
Contribuições da equipe github.com/Guilherme-RCM/projeto-integrador-eixoII-GRUPO1-/pulse	A atividade do repositório da equipe: commits, *pull requests* e quem contribuiu em cada período.
Painel interativo (protótipo em HTML) — abrir no navegador raw.githack.com/Guilherme-RCM/projeto-integrador-eixoII-GRUPO1-/main/SPRINT-3/painel_interativo_sefin.html arquivo no repositório: SPRINT-3/painel_interativo_sefin.html	O painel do Módulo 5, que simula o Power BI com filtro cruzado por tributo e período. O primeiro link abre o painel funcionando, direto do GitHub; o segundo leva ao arquivo, que também pode ser baixado e aberto em qualquer navegador.
Histórico de desenvolvimento github.com/guilhermercmoraes-tech/PI2_Sprint2-Grupo-1-UFT	Os 36 commits da Sprint 3 na *branch* `sprint-3`, mesclada na `main`, e os *quality gates* executados pelo GitHub Actions a cada envio.

3. Verificação da versão unificada

A versão unificada foi verificada como faria um avaliador, a partir de um clone limpo, sem o arquivo de credenciais e sem nenhum dado local, com as dependências do `requirements-dev.txt` e um MySQL 8.4 de teste; a execução completa com os dados reais foi feita na cópia de trabalho do grupo.

Verificação	Resultado
Execução do *pipeline*	Execução de referência de 21/10/2026 (`20261021T065740-9b9054`): sete fontes coletadas, 33 de 33 validações impeditivas, carga no MySQL e EDA, em três minutos e meio. Reprocessamento de 26/10 com o código final (`20261026T155511-c3ba7c`): 33 de 33 e banco igual aos arquivos
Teste da versão unificada	Com o bruto de 21/10 incluído na pasta, `python etl_sefin.py --offline --sem-banco` terminou com código 0, 33 de 33 validações e a EDA regenerada em cerca de 30 s, inclusive num clone com conversão de fim de linha do Windows
Testes automatizados	782 aprovados no clone limpo: 722 unitários, 45 de integração com MySQL e 15 cenários Gherkin
Quality gates G1–G14	Os 14 aprovados em 26/10/2026: cobertura de 99,3%, complexidade máxima 10, 9/9 contratos de dependência, 0 erros de tipo, mutação de 94,1%, pior P95 de 2,54 s, 75/75 DOIs conferidos e 17/17 arquivos idênticos entre duas transformações
Simulação do GitHub Actions	O mesmo comando do *workflow*, num clone sem dados, achou e permitiu corrigir um defeito do gate G14 antes do envio; depois da correção, aprovado
Segurança da publicação	Nenhuma senha, chave ou dado pessoal real nos 53 commits do histórico; dados coletados, credenciais e logs locais ficam fora do Git

4. Pontos positivos de cada entrega

Além de cumprir o que o enunciado pede, cada entrega antecipa um problema que só apareceria mais tarde: quando a fonte mudar, quando a base da Sefin chegar ou quando outra pessoa precisar refazer o trabalho. Os números vêm da verificação da seção 3 e dos documentos de cada entrega.

4.1 E1 — Coleta automatizada

A coleta foi desenhada para que o dado chegue íntegro e para que o servidor público que o fornece não pague o preço da automação. Thelwall e Stuart (2006) lembram que um coletor impõe custo ao servidor e precisa se identificar e respeitar as regras do site; por isso, cada host tem o seu *robots.txt* consultado e interpretado conforme o protocolo padronizado pela IETF (KOSTER et al., 2022), as requisições respeitam um ritmo mínimo por servidor e, diante de falha temporária, a coleta espera de forma exponencial entre as tentativas (METCALFE; BOGGS, 1976) e obedece ao cabeçalho *Retry-After* (IETF, 2022). A conexão só é aceita com TLS 1.2 ou superior e com certificado verificado, depois que a IETF descontinuou as versões 1.0 e 1.1 (MORIARTY; FARRELL, 2021). O bruto, por sua vez, é datado, nunca sobrescrito e registrado num manifesto em que cada entrada carrega o resumo SHA-256 da anterior, técnica de encadeamento que torna detectável qualquer alteração posterior (HABER; STORNETTA, 1991). Quando o portal NUCLEOGOV respondeu 403, a recusa foi registrada, e a receita recente veio da extração oficial distribuída pela coordenação, conferida pelo *hash*; a API do portal descrita no manual de coleta ficou implementada como alternativa explícita (ADR-002).

- Sete fontes oficiais num único comando: API da Prefeitura (3.542 registros em 36 páginas), extração NUCLEOGOV (176.993 linhas), GeoPalmas (6 regiões e 284 quadras), setores do IBGE por WFS (733), renda do Censo 2022, descoberta por raspagem do índice do servidor, e IPCA do Banco Central (321 meses).
- Paginação conferida contra o total anunciado por cada fonte (validação V01) e cadeia do manifesto conferida antes de qualquer leitura (V12).
- Nenhum dado pessoal coletado; o log mascara senhas e chaves e não grava caminhos do computador.

Onde ver: E1_coleta.md · pipeline/coleta · log da execução de referência

4.2 E2 — Pipeline ETL de ponta a ponta

O *pipeline* foi organizado em filtros independentes porque cada fonte e cada regra mudam em ritmos diferentes. No estilo de *pipes* e filtros, cada filtro recebe uma entrada, produz uma saída e não conhece os demais (GARLAN; SHAW, 1993; VALENTE, 2020, §7.7), o que aplica a recomendação de Parnas (1972) de decompor o sistema pelas decisões que tendem a mudar. A independência não ficou na intenção: nove contratos de dependência, conferidos a cada integração, impedem que um filtro de limpeza acesse a rede ou o banco, e Perry e Wolf (1992) definem a arquitetura justamente pelas restrições que ela impõe. A consequência apareceu durante a própria sprint, quando a fonte do NUCLEOGOV foi trocada duas vezes sem que nenhum filtro precisasse mudar. Entre os filtros, as validações classificam cada regra numa dimensão de qualidade (WANG; STRONG, 1996; BATINI et al., 2009) e, se uma impeditiva reprova, nada é gravado, nem nas camadas nem no banco, como recomenda a apostila de ETL do Módulo 5 (§10.3). Cada execução recebe um identificador que aparece em todas as linhas do log, no registro do banco e no relatório de qualidade, o que liga as três evidências (SIMMHAN; PLALE; GANNON, 2005).

- `etl_sefin.py` com *extract*, *transform* e *load*; limpeza com 21 decisões documentadas e a identidade lidos = aceitos + rejeitados + descartados exigida para todas as fontes.
- Enriquecimento com o Censo 2022: 733 setores e 283 quadras em 1.635 pares, com interpolação por área (LAM, 1983); atributos de tempo de inadimplência, sazonalidade e faixas de valor, classificados pelo momento em que ficam disponíveis, para evitar vazamento no modelo da Sprint 4 (KAUFMAN et al., 2012).
- 12 validações impeditivas e 5 informativas, cada uma com um teste que a reprova de propósito; carga transacional e idempotente no MySQL da Sprint 2, que também completou a carga das 176.993 linhas do NUCLEOGOV pendente desde a Sprint 2.

Onde ver: E2_pipeline.md · limpeza_decisoes.md · ADRs.md · etl_sefin.py

4.3 E3 — Análise exploratória (EDA)

A análise exploratória foi tratada como uma afirmação que o leitor pode conferir, e não como uma coleção de gráficos. Anscombe (1973) mostrou que conjuntos com as mesmas estatísticas resumidas podem ter formas completamente diferentes, e Weissgerber et al. (2015) pedem que a distribuição seja mostrada, e não só a média; por isso, o relatório é gerado por script a partir das camadas do *pipeline*, cada figura tem como título a frase que afirma o achado, com o número calculado dos próprios dados, e uma tabela repete os mesmos valores. A forma de cada gráfico segue a percepção gráfica, que favorece a posição numa escala comum (CLEVELAND; McGILL, 1984), e os mapas coropléticos usam classes por quantis (BREWER; PICKLE, 2002). O cuidado com a interpretação acompanha o cuidado com a forma: a renda do setor não descreve o contribuinte individual, sob pena da falácia ecológica (ROBINSON, 1950), e o padrão espacial é medido pelo I de Moran (MORAN, 1950), em vez de inferido a olho.

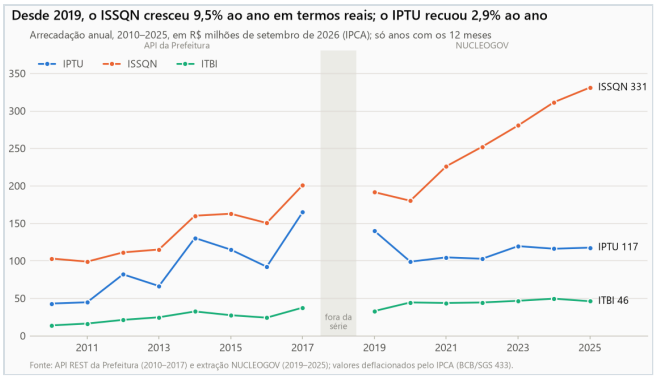


Figura 1 — Desde 2019, o ISSQN cresceu 9,5% ao ano em termos reais, e o IPTU recuou 2,9% ao ano (valores deflacionados pelo IPCA).

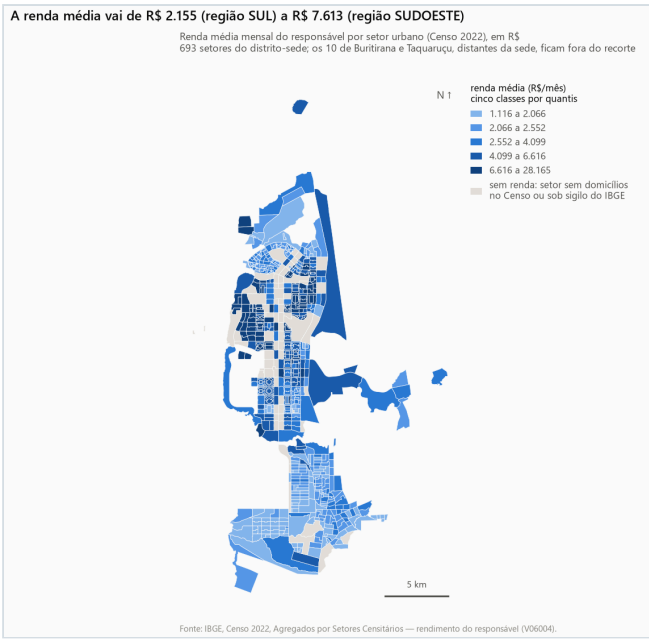


Figura 6 — A renda média por setor urbano vai de R$ 2.155 (região Sul) a R$ 7.613 (região Sudoeste), com I de Moran de 0,76.

- Sete figuras (evolução, composição, sazonalidade, distribuição, relação e dois mapas por setor urbano) com frase de leitura e tabela; o mapa de inadimplência e a relação com a renda levam a marca SIMULADO.
- Três achados reais orientam a Sprint 4: o ISSQN passou de 53% para 67% da arrecadação dos três tributos; a dívida ativa chegou a 48% do IPTU arrecadado em 2019 e caiu para 16% em 2025; e o IPTU arrecada em março 3,5 vezes a média mensal.
- Indicadores de gestão em valores reais e a lista das limitações da própria análise ao fim do relatório.

Onde ver: EDA.md · GALERIA.md · pipeline/eda

4.4 E4 — Reprodutibilidade e organização

A reprodutibilidade foi tratada no sentido mais estrito, em que a mesma entrada gera os mesmos bytes, porque só assim um número do relatório pode ser conferido por outra pessoa. Lamb e Zacchiroli (2022) mostram que a reprodução bit a bit é o que permite verificar a integridade de um produto de software, e Sandve et al. (2013) incluem entre as regras básicas registrar versões, sementes e cada execução; por isso, a simulação usa semente fixa, os arquivos têm formato determinístico, e o gate G14 transforma o bruto duas vezes, em pastas novas, e exige 17 de 17 arquivos idênticos. O *README* descreve o caminho a partir de um clone novo, com e sem rede, as dependências com faixas de versão e as pastas `data/bruto`, `data/limpo` e `data/pronto`. A verificação desse caminho também mostrou o seu valor: rodar os gates num clone sem dados, como fará o GitHub Actions, revelou que o G14 quebrava quando faltava o bruto real, defeito invisível na cópia de trabalho e corrigido antes do envio, com um teste que impede o seu retorno.

- Execução do zero documentada, com os códigos de saída (0 sucesso, 2 validação reprovada, 3 falha de coleta) e testes que rodam sem MySQL.
- Decisões registradas com as alternativas descartadas (ADR-001 a ADR-003), dicionário da base analítica e rastreabilidade das histórias de usuário até os testes.
- Divisão de trabalho por entregável no *README* e diário de bordo com a evidência de cada atividade.

Onde ver: README.md · SPRINT3.md · diário de bordo

4.5 Qualidade, comum a todas as entregas

A qualidade foi mantida como um resultado que qualquer pessoa pode repetir com um único comando, e não como uma afirmação do grupo. Os quatorze *quality gates* da Sprint 2 e da Sprint 3 rodam no GitHub Actions a cada envio, com exceção da mutação, que é lenta e roda semanalmente; os quatro novos desta sprint medem o desempenho das consultas do painel, a qualidade da última execução real, com a conferência do banco contra os arquivos, os DOIs da bibliografia e a reprodutibilidade. A complexidade ciclomática máxima ficou em 10, no limite proposto por McCabe (1976), e os testes de mutação, que inserem defeitos artificiais e verificam se algum teste os detecta (DEMILLO; LIPTON;

SAYWARD, 1978), passaram a cobrir os filtros da Sprint 3, com 94,1% dos 2.829 mutantes detectados. Por conseguinte, a cobertura de 99,3% não é um número isolado: ela vem acompanhada da prova de que os testes reagem quando o código erra.

- 782 testes na forma da pirâmide recomendada por Valente (2020, cap. 8): 722 unitários, 45 de integração com MySQL e 15 cenários de aceitação em Gherkin.
- Consultas agregadas do painel abaixo de 3 s no P95 (RNF-04) e as 75 referências com DOI conferidas no Crossref.

Onde ver: qualidade.md · mutacao.md · REFERENCIAS.md

4.6 Painel interativo do Módulo 5 (protótipo em HTML)

O painel interativo transforma os achados da EDA numa ferramenta de consulta, e foi construído sobre as mesmas tabelas da camada `data/pronto` para que o gestor e o relatório nunca mostrem números diferentes. Enquanto um relatório responde às perguntas que o analista escolheu, um painel permite que o próprio gestor da Sefin faça as suas, recortando o período e o tributo; por isso, os títulos dos visuais repetem as frases de leitura da EDA, as séries usam posição numa escala comum, como recomendam Cleveland e McGill (1984), e o que é simulado continua marcado como tal. O filtro cruzado é o recurso central: ao escolher um tributo, a série selecionada se destaca, as demais esmaecem e os indicadores do topo são recalculados, de modo que, com o IPTU selecionado, a arrecadação real de 2010 a 2025 passa a R$ 1.536,2 milhões e a participação da dívida ativa, a 28,4%. A segunda página reúne a simulação (ADR-003) e os mapas por setor urbano, com a correlação e o I de Moran ao lado de cada visual. Trata-se de um protótipo em HTML, autossuficiente e aberto em qualquer navegador; o arquivo `.pbix` do Power BI, montado com o mesmo tema, as consultas e as medidas, continua pendente (seção 5).

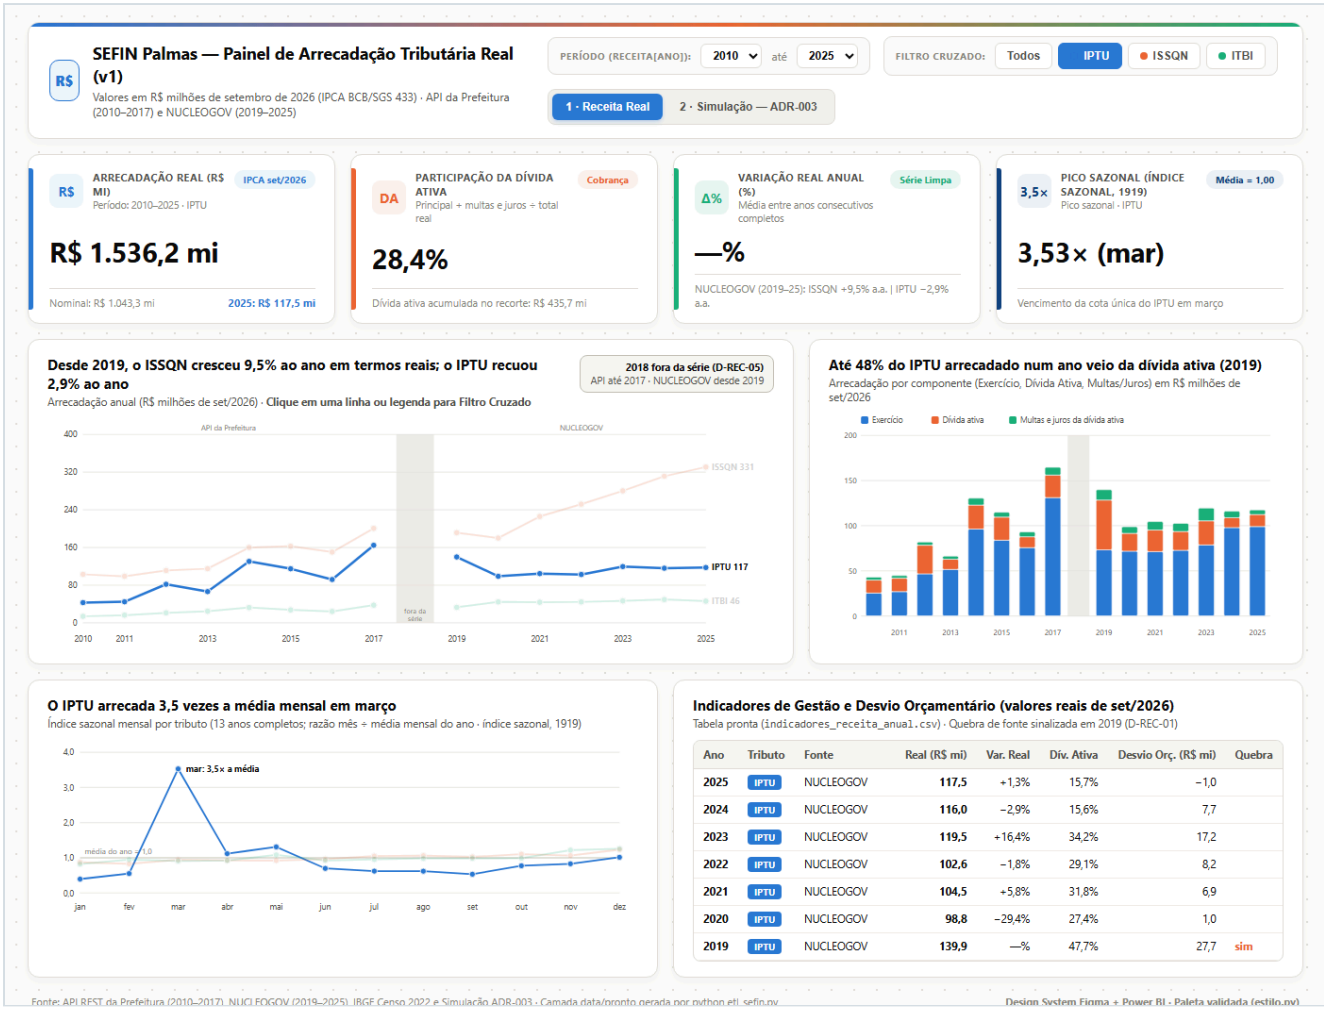


Figura 8 — Página 1 do painel com o filtro cruzado no IPTU: a série do IPTU se destaca, ISSQN e ITBI esmaecem, e os indicadores e a tabela passam a mostrar só o IPTU (captura do protótipo em HTML, 26/10/2026).

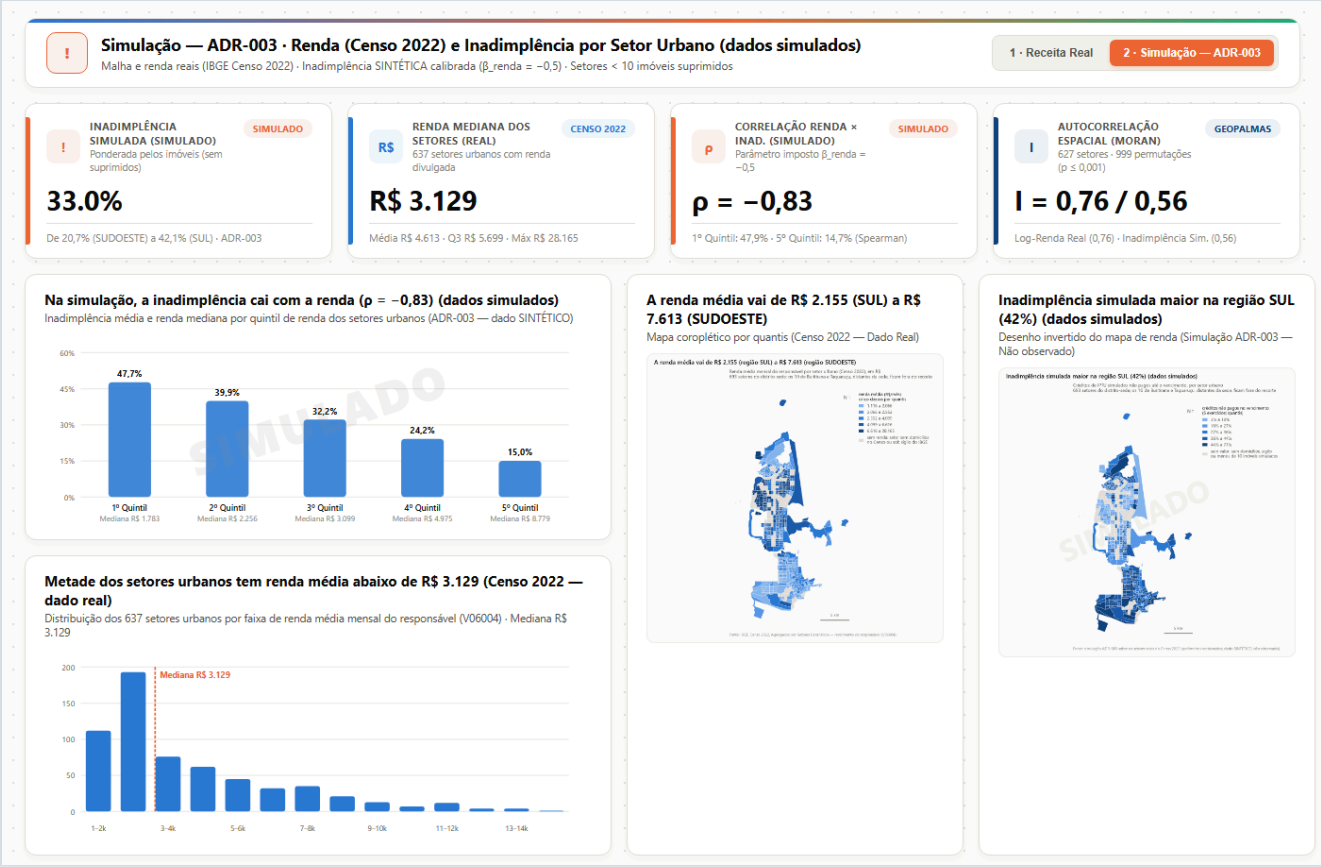


Figura 9 — Página 2 do painel: inadimplência por quintil de renda e mapa da inadimplência, ambos simulados (ADR-003), ao lado da distribuição e do mapa da renda real do Censo 2022.

Onde ver: abrir o painel no navegador · painel_interativo_sefin.html · power_bi.md

5. Limitações e impedimentos para a Sprint 4

As limitações desta entrega vêm da ausência de dados por contribuinte, e não de falhas do processo, e por isso foram declaradas em vez de contornadas. A simulação da dívida de IPTU segue o planejamento recomendado para estudos de simulação, com objetivo, mecanismo gerador e semente explícitos (MORRIS; WHITE; CROWTHER, 2019), e a direção do gradiente de renda vem da literatura sobre inadimplência do imposto predial (ALM et al., 2014); contudo, a intensidade do efeito é uma premissa, e todo padrão territorial da inadimplência é propriedade da simulação, e não achado. Desse modo, o modelo da Sprint 4 só poderá ser validado como método enquanto a base de créditos da Sefin não chegar.

Impedimentos: (1) sem a base de créditos da Sefin, o modelo da Sprint 4 só pode ser treinado sobre a simulação; a pseudonimização na entrada está especificada para quando a base chegar; (2) o valor de 2017 da API supera em 18% o maior ano do NUCLEOGOV e precisa ser conferido com as demonstrações contábeis do município; (3) o escopo do score, individual ou territorial, depende de decisão com a coordenação.
Pendências da equipe: painel `.pbix` do Módulo 5, montado no Power BI Desktop conforme `docs/sprint3/power_bi.md` (o protótipo interativo em HTML da seção 4.6 já acompanha a entrega), e o registro de cada integrante no diário de bordo.

Relatório elaborado com apoio de ferramenta de IA (Claude Code), por execução do código, leitura do repositório e consulta às referências citadas; não substitui a correção oficial da coordenação.

Referências

ALM; HODGE; SANDS et al. Detroit Property Tax Delinquency: Social Contract in Crisis. *Public Finance and Management*, v. 14, n. 3, p. 280-305, 2014. DOI: 10.1177/152397211401400302.

ANSCOMBE. Graphs in Statistical Analysis. *The American Statistician*, v. 27, n. 1, p. 17-21, 1973. DOI: 10.1080/00031305.1973.10478966.

BATINI; CAPPIELLO; FRANCALANCI et al. Methodologies for data quality assessment and improvement. *ACM Computing Surveys*, v. 41, n. 3, p. 1-52, 2009. DOI: 10.1145/1541880.1541883.

BOX. Science and Statistics. *Journal of the American Statistical Association*, v. 71, n. 356, p. 791-799, 1976. DOI: 10.1080/01621459.1976.10480949.

BREWER; PICKLE. Evaluation of Methods for Classifying Epidemiological Data on Choropleth Maps in Series. *Annals of the Association of American Geographers*, v. 92, n. 4, p. 662-681, 2002. DOI: 10.1111/1467-8306.00310.

CLEVELAND; MCGILL. Graphical Perception: Theory, Experimentation, and Application to the Development of Graphical Methods. *Journal of the American Statistical Association*, v. 79, n. 387, p. 531-554, 1984. DOI: 10.1080/01621459.1984.10478080.

DEMILLO; LIPTON; SAYWARD. Hints on Test Data Selection: Help for the Practicing Programmer. *Computer*, v. 11, n. 4, p. 34-41, 1978. DOI: 10.1109/C-M.1978.218136.

GARLAN; SHAW. AN INTRODUCTION TO SOFTWARE ARCHITECTURE. *Series on Software Engineering and Knowledge Engineering*, p. 1-39, 1993. DOI: 10.1142/9789812798039_0001.

HABER; STORNETTA. How to time-stamp a digital document. *Journal of Cryptology*, v. 3, n. 2, p. 99-111, 1991. DOI: 10.1007/BF00196791.

IETF. HTTP Semantics. *RFC Editor*, 2022. DOI: 10.17487/RFC9110.

KAUFMAN; ROSSET; PERLICH et al. Leakage in data mining: Formulation, detection, and avoidance. *ACM Transactions on Knowledge Discovery from Data*, v. 6, n. 4, p. 1-21, 2012. DOI: 10.1145/2382577.2382579.

KOSTER; ILLYES; ZELLER et al. Robots Exclusion Protocol. *RFC Editor*, 2022. DOI: 10.17487/RFC9309.

LAM. Spatial Interpolation Methods: A Review. *The American Cartographer*, v. 10, n. 2, p. 129-150, 1983. DOI: 10.1559/152304083783914958.

LAMB; ZACCHIROLI. Reproducible Builds: Increasing the Integrity of Software Supply Chains. *IEEE Software*, v. 39, n. 2, p. 62-70, 2022. DOI: 10.1109/MS.2021.3073045.

Material didático do Módulo 5, Eixo II BIINAR/UFT. *ETL: apostila completa — do dado bruto à informação confiável*. Edição de outubro de 2026, 2026. Sem DOI.

MCCABE. A Complexity Measure. *IEEE Transactions on Software Engineering*, v. SE-2, n. 4, p. 308-320, 1976. DOI: 10.1109/TSE.1976.233837.

METCALFE; BOGGS. Ethernet: distributed packet switching for local computer networks. *Communications of the ACM*, v. 19, n. 7, p. 395-404, 1976. DOI: 10.1145/360248.360253.

MORAN. NOTES ON CONTINUOUS STOCHASTIC PHENOMENA. *Biometrika*, v. 37, n. 1-2, p. 17-23, 1950. DOI: 10.1093/biomet/37.1-2.17.

MORIARTY; FARRELL. Deprecating TLS 1.0 and TLS 1.1. *RFC Editor*, 2021. DOI: 10.17487/RFC8996.

MORRIS; WHITE; CROWTHER. Using simulation studies to evaluate statistical methods. *Statistics in Medicine*, v. 38, n. 11, p. 2074-2102, 2019. DOI: 10.1002/sim.8086.

PARNAS. On the criteria to be used in decomposing systems into modules. *Communications of the ACM*, v. 15, n. 12, p. 1053-1058, 1972. DOI: 10.1145/361598.361623.

PERRY; WOLF. Foundations for the study of software architecture. *ACM SIGSOFT Software Engineering Notes*, v. 17, n. 4, p. 40-52, 1992. DOI: 10.1145/141874.141884.

POLYZOTIS; ROY; WHANG et al. Data Lifecycle Challenges in Production Machine Learning: A Survey. *ACM SIGMOD Record*, v. 47, n. 2, p. 17-28, 2018. DOI: 10.1145/3299887.3299891.

ROBINSON. Ecological Correlations and the Behavior of Individuals. *American Sociological Review*, v. 15, n. 3, p. 351, 1950. DOI: 10.2307/2087176.

SANDVE; NEKRUTENKO; TAYLOR et al. Ten Simple Rules for Reproducible Computational Research. *PLoS Computational Biology*, v. 9, n. 10, p. e1003285, 2013. DOI: 10.1371/journal.pcbi.1003285.

SCHELTER; LANGE; SCHMIDT et al. Automating large-scale data quality verification. *Proceedings of the VLDB Endowment*, v. 11, n. 12, p. 1781-1794, 2018. DOI: 10.14778/3229863.3229867.

SIMMHAN; PLALE; GANNON. A survey of data provenance in e-science. *ACM SIGMOD Record*, v. 34, n. 3, p. 31-36, 2005. DOI: 10.1145/1084805.1084812.

THELWALL; STUART. Web crawling ethics revisited: Cost, privacy, and denial of service. *Journal of the American Society for Information Science and Technology*, v. 57, n. 13, p. 1771-1779, 2006. DOI: 10.1002/asi.20388.

VALENTE, Marco Tulio. *Engenharia de Software Moderna: princípios e práticas para desenvolvimento de software com produtividade*. Belo Horizonte: edição do autor. Disponível em: https://engsoftmoderna.info, 2020. Sem DOI.

VASSILIADIS. A Survey of Extract–Transform–Load Technology. *International Journal of Data Warehousing and Mining*, v. 5, n. 3, p. 1-27, 2009. DOI: 10.4018/jdwm.2009070101.

WANG; STRONG. Beyond Accuracy: What Data Quality Means to Data Consumers. *Journal of Management Information Systems*, v. 12, n. 4, p. 5-33, 1996. DOI: 10.1080/07421222.1996.11518099.

WEISSGERBER; MILIC; WINHAM et al. Beyond Bar and Line Graphs: Time for a New Data Presentation Paradigm. *PLOS Biology*, v. 13, n. 4, p. e1002128, 2015. DOI: 10.1371/journal.pbio.1002128.

WILSON; BRYAN; CRANSTON et al. Good enough practices in scientific computing. *PLOS Computational Biology*, v. 13, n. 6, p. e1005510, 2017. DOI: 10.1371/journal.pcbi.1005510.