Projeto Integrador PI2 · Eixo II · BIINAR/UFT · 2026/2

HISTÓRIAS DE USUÁRIO E TRANSFORMAÇÃO DE DADOS NÃO ESTRUTURADOS EM ESTRUTURADOS PARA A COBRANÇA TRIBUTÁRIA MUNICIPAL: FUNDAMENTAÇÃO EM GOVERNANÇA DIGITAL

Autoria: equipe do PI2 (Eixo II)

Estudo de caso: Inteligência Tributária de Palmas-TO

Palmas-TO
Outubro de 2026

RESUMO

A cobrança de tributos municipais depende de um fluxo de dados que começa em documentos heterogêneos e termina em um ato administrativo auditável. Este artigo investiga, a partir de histórias de usuário do servidor da fazenda municipal, quais tipos de dados atravessam esse fluxo, em qual etapa cada um se torna estruturado e de que forma a governança digital pode reduzir a distância entre cidadão e município na cobrança. A pesquisa bibliográfica, restrita a publicações com DOI verificado, sustenta um pipeline de quatro estágios (aquisição, semiestruturação, estruturação e interpretação) no qual modelos de linguagem extraem campos de documentos não estruturados e regras determinísticas decidem o que é publicado. O estudo de caso usa o Projeto Integrador de Palmas-TO, cujo módulo de receita já valida e concilia dados reais. Conclui-se que a extração assistida por inteligência artificial só é confiável quando sua saída passa por validação de contrato, conciliação e revisão humana proporcional ao risco.

Palavras-chave: tributação municipal; governança digital; histórias de usuário; extração de informação; ETL; dados semiestruturados.

1 INTRODUÇÃO

A arrecadação dos municípios brasileiros depende de uma cadeia de dados que raramente é tratada como um sistema único. O Imposto Predial e Territorial Urbano (IPTU) e o Imposto Sobre Serviços (ISS) são lançados a partir de cadastros, pagos em prazos fixados em lei, e, quando não quitados, inscritos em dívida ativa. Cada uma dessas etapas produz registros em formatos diferentes: planilhas de receita publicadas em portais, guias e comprovantes de pagamento, petições de contribuintes em PDF e pareceres redigidos em texto livre. Estudos sobre administração tributária local mostram que parte do potencial de arrecadação permanece sem uso, e que essa lacuna tende a ser maior nos municípios menores (CASTRO; AFONSO, 2017).

O problema central deste trabalho é que a informação necessária para cobrar bem está distribuída entre esses formatos, e a maior parte dela não chega ao gestor em condição de ser comparada, priorizada ou auditada. Quando um documento não estruturado permanece como anexo, o servidor precisa lê-lo, digitá-lo e conferi-lo manualmente, o que consome tempo e introduz erros. Quando a conferência é feita depois da publicação, o erro já alcançou o painel de decisão. Assim, a questão de pesquisa é: como transformar, de forma verificável, os dados não estruturados da cobrança municipal em dados estruturados que sustentem decisões e a comunicação com o cidadão?

O objetivo geral é propor um pipeline de dados, orientado por histórias de usuário, que descreva o percurso da informação desde a entrada do dado bruto até a cobrança, com a classificação de cada tipo de dado em cada etapa e com um mecanismo de inteligência artificial capaz de semiestruturar documentos. Os objetivos específicos são: (i) identificar, na literatura com DOI, fundamentos sobre governança digital na administração tributária local; (ii) especificar histórias de usuário do servidor que cubram o percurso de cobrança; (iii) classificar os dados por etapa quanto ao grau de estruturação; (iv) apontar técnicas acadêmicas de transformação de dados não estruturados, com o respectivo script automático de referência; e (v) avaliar o estágio atual do estudo de caso frente a esse pipeline.

A justificativa está na combinação de dois problemas pouco tratados em conjunto. A literatura de governança digital descreve a integração de serviços públicos em termos amplos, enquanto a literatura de engenharia de dados trata a limpeza e a integração de registros sem relacioná-las à cobrança de tributos. Ao ligar as duas perspectivas por meio de histórias de usuário, o artigo oferece um roteiro que pode orientar tanto o projeto de sistemas quanto a avaliação de sua aderência às necessidades do servidor e do cidadão.

O texto está organizado da seguinte forma. A seção 2 apresenta a fundamentação teórica. A seção 3 descreve o método de busca e os critérios de inclusão. A seção 4 apresenta as histórias de usuário, a classificação dos dados e o pipeline de ação. A seção 5 detalha o sistema de transformação com inteligência artificial. A seção 6 avalia o estudo de caso, a seção 7 discute limitações e a seção 8 conclui o trabalho.

2 FUNDAMENTAÇÃO TEÓRICA

2.1 Governança digital e administração tributária local

A governança digital redefine a relação entre Estado e cidadão ao substituir a prestação fragmentada de serviços por um modelo integrado, centrado nas necessidades do usuário e apoiado em dados. Dunleavy et al. (2006) argumentam que a administração pública em era digital combina três movimentos: a reintegração de funções antes separadas, uma organização holística voltada às necessidades dos cidadãos e a digitalização dos processos. Para a tributação, esses movimentos significam que o contribuinte deve ser capaz de consultar, contestar e negociar sua dívida por um canal único, e que o registro dessas interações deve alimentar a gestão interna sem nova digitação.

Na prática brasileira, a inovação administrativa e tecnológica na arrecadação de IPTU, ISS e ITBI tem sido avaliada por métodos de eficiência comparativa. Cabello et al. (2026) investigam como as inovações desses municípios se relacionam com o desempenho

fiscal, empregando análise envoltória de dados em três estágios, índice de produtividade de Malmquist e análise qualitativa comparada de conjuntos fuzzy. A relevância desse trabalho para este artigo está na tese de que as práticas tecnológicas não produzem resultado isoladamente: elas se combinam com outras condições administrativas, o que reforça a necessidade de tratar o pipeline de dados como um conjunto integrado.

Essa integração é importante porque a cobrança é, em essência, um problema de priorização sob recursos limitados. Castro e Afonso (2017), ao aplicar a teoria dos conjuntos fuzzy ao IPTU, mostram que a utilização do potencial de arrecadação varia entre municípios e que a diferença se concentra nas cidades de menor porte. No plano internacional, a OCDE (2014) trata de como tornar a gestão da dívida tributária mais eficiente, com uso de análise de dados e de comunicação com o contribuinte. Hutton (2017), ao descrever a metodologia do programa de análise da lacuna de receita do Fundo Monetário Internacional, mostra que a estimativa da diferença entre o tributo devido e o arrecadado depende da comparabilidade entre os dados de lançamento e de pagamento.

2.2 Dados estruturados, semiestruturados e não estruturados

A classificação do grau de estruturação de um dado orienta a escolha das técnicas de tratamento. Buneman (1997) caracteriza os dados semiestruturados como informação que não obedece a um esquema rígido previamente declarado, mas que carrega, em si mesma, rótulos que descrevem sua forma. Um registro com campos opcionais, uma resposta de portal em formato JSON ou um documento XML com elementos repetidos ilustram essa categoria. Dados tabulares com colunas fixas e tipos definidos são estruturados; textos livres, imagens digitalizadas e PDFs sem camada de texto são não estruturados.

Essas categorias não são estanques, e a passagem de uma para outra é o núcleo da engenharia de dados. Vassiliadis (2009) organiza o processo de extração, transformação e carga (ETL) e trata a transformação como fase distinta da carga, o que é consistente com a sequência proposta neste artigo, em que a semiestruturação precede a estruturação.

A qualidade dos dados, por sua vez, condiciona a utilidade de qualquer transformação. Chu et al. (2016) apresentam uma visão geral da limpeza de dados como problema que envolve detecção de erros, reparo e verificação, e destacam que essas tarefas são interdependentes. Abedjan et al. (2016) avaliam experimentalmente ferramentas de detecção de erros e reportam que nenhum método isolado domina todos os tipos de falha, o que sustenta combinar diferentes abordagens de detecção. Para a cobrança, isso significa que um valor lançado em duplicidade, um CPF inválido ou um total que não fecha com a soma de seus componentes precisam ser detectados antes da publicação.

2.3 Histórias de usuário e arquitetura de software

As histórias de usuário são a forma mais difundida de expressar requisitos em projetos ágeis, e sua qualidade determina o que o time de arquitetura consegue decidir. Amna e Poels (2022) realizaram um mapeamento sistemático da pesquisa sobre histórias de usuário, classificando os estudos segundo a atividade de engenharia de requisitos, a classe de problema e o resultado obtido, o que permite localizar lacunas na literatura.

Essa ligação é o ponto em que Gilson, Galster e Georis (2019) avançam. Os autores propõem extrair atributos de qualidade do sistema a partir do texto das histórias de usuário, com o objetivo de apoiar decisões arquiteturais já nas fases iniciais do projeto. Para este artigo, a implicação é que os critérios de aceitação de cada história devem explicitar requisitos não funcionais, como a rastreabilidade de uma alteração de dívida ou o tempo máximo de resposta do painel do gestor, pois são eles que levam a escolhas de armazenamento, de processamento e de auditoria.

2.4 Extração de informação com modelos de linguagem

A extração de informação, tradicionalmente dividida em reconhecimento de entidades, relações e eventos, passou a ser feita com modelos de linguagem de grande porte. Xu et al. (2024), em revisão sobre extração generativa de informação, descrevem como esses modelos podem produzir diretamente registros estruturados a partir de texto, e discutem os desafios de consistência e de verificação dos resultados. A distinção entre gerar um campo e verificar o campo gerado é central para o restante deste artigo.

Uma aplicação concreta desse princípio aparece em Spavound, Schaer e Markou (2026), que descrevem um pipeline em dois estágios para converter PDFs em JSON pronto para análise: primeiro uma leitura visual do documento, depois a estruturação por um modelo de linguagem. A separação entre leitura e estruturação permite auditar cada etapa e localizar onde um erro foi introduzido, requisito que a administração tributária precisa atender para justificar um ato de cobrança.

3 MÉTODO DE PESQUISA

Trata-se de pesquisa bibliográfica exploratória, com estudo de caso documental. As buscas foram realizadas em mecanismo de busca na web, com termos em português e inglês combinando administração tributária municipal, governança digital, dívida ativa, histórias de usuário, extração de informação e ETL. Os resultados foram então verificados individualmente, resolvendo-se cada DOI pelo serviço oficial de resolução e conferindo-se título, autoria, periódico e ano pelos metadados da Crossref ou da página da editora.

Foram adotados três critérios de inclusão. O primeiro exige DOI verificado, conforme a exigência deste trabalho. O segundo exige que a publicação trate diretamente de tributação, governança digital, histórias de usuário, qualidade de dados ou extração de informação. O terceiro exige que título, autoria, periódico e ano tenham sido conferidos nos metadados oficiais. A leitura integral dos textos não foi feita: cada afirmação atribuída a uma obra restringe-se ao alcance que seu título, seu resumo e os metadados permitem, e as afirmações mais específicas foram formuladas com cautela. Documentos sem DOI, como relatórios institucionais, legislação e notas técnicas, são usados somente como contexto normativo e não como respaldo acadêmico de afirmações.

Três fontes encontradas nas buscas foram excluídas. Um trabalho sobre extração com modelos de linguagem publicado na conferência ISD 2025 foi descartado por não apresentar DOI nos resultados. Um método que combina processamento de linguagem natural e transformação dirigida por modelos, publicado no Bulletin of Electrical Engineering and Informatics, foi descartado porque seu DOI não pôde ser conferido. Por fim, um levantamento sobre cobrança municipal em repositórios de trabalhos de conclusão de curso foi descartado por não ter DOI.

A principal limitação do método é a ausência de busca em bases bibliográficas estruturadas, como Scopus ou Web of Science, o que pode omitir publicações relevantes, e a leitura parcial dos textos, já mencionada. Além disso, a literatura com DOI sobre governança digital municipal brasileira é escassa nos resultados obtidos, o que se reflete na seção 7.

4 HISTÓRIAS DE USUÁRIO E PIPELINE DE AÇÃO DO SERVIDOR

4.1 Atores e escopo

O ator principal é o servidor da fazenda municipal, responsável por lançar, conferir e cobrar créditos. O cidadão, como contribuinte, aparece como ator secundário, com acesso restrito a consultas e negociações. O escopo abrange o percurso do dado desde a publicação da receita pela prefeitura até a cobrança e a negociação de um crédito inscrito em dívida ativa. A estimativa territorial de arrecadação, prevista em outra camada do sistema, é tratada apenas como consumidora dos dados.

4.2 Histórias de usuário

As histórias abaixo seguem o formato papel, ação e benefício, com critérios de aceitação que explicitam requisitos não funcionais, conforme a orientação de Gilson, Galster e Georis (2019).

- **HU-01.** Como servidor da fazenda, quero importar o arquivo de receita publicado pela prefeitura, para que a base reflita a arrecadação oficial. *Critérios:* o arquivo é identificado por seu SHA-256; uma segunda importação do mesmo arquivo não grava nada; um arquivo que viole o contrato de layout é registrado como rejeitado, sem publicação parcial.
- **HU-02.** Como servidor, quero ver os erros, avisos e divergências de cada importação, para decidir se o arquivo pode ser usado. *Critérios:* cada ocorrência indica a linha de origem; o resumo é o mesmo em qualquer reexecução.
- **HU-03.** Como servidor, quero que o total de cada tributo seja conferido com a soma de seus componentes, para não contar o mesmo valor duas vezes. *Critérios:* divergência de centavos é tratada como erro; o total não entra na soma.
- **HU-04.** Como servidor, quero que documentos enviados pelo contribuinte, como requerimentos e certidões em PDF, sejam convertidos em registros estruturados que eu possa revisar, para reduzir a digitação manual. *Critérios:* cada campo extraído traz o trecho do documento de origem e um indicador de confiança; nenhum campo é publicado sem validação de tipo e de regra de negócio.
- **HU-05.** Como servidor, quero uma fila de cobrança ordenada por classe de prioridade, prazo e score, para atacar primeiro os créditos de maior retorno esperado. *Critérios:* a ordem é reconstruída após cada alteração; um crédito pago sai da fila.
- **HU-06.** Como servidor, quero registrar uma negociação sobre um crédito, para que exista no máximo uma negociação ativa por crédito. *Critérios:* a regra é garantida pelo banco de dados, não apenas pela aplicação; toda mudança de situação é auditada.
- **HU-07.** Como cidadão autenticado, quero consultar a situação dos meus créditos e solicitar uma negociação por meio de login único do governo federal, para resolver a dívida sem deslocamento. *Critérios:* o cidadão vê apenas os próprios créditos; a autenticação segue o protocolo do login único.
- **HU-08.** Como gestor, quero comparar a arrecadação observada com a estimada por região e por tributo, para identificar desvios que exijam ação. *Critérios:* a estimativa aparece com intervalo e com a versão do modelo; dados observados e estimados têm rótulos distintos.

4.3 Classificação dos dados por etapa

A tabela 1 classifica os dados que atravessam o pipeline segundo o grau de estruturação, a origem e a etapa em que o dado passa a ter forma tabular confiável. A classificação segue a distinção de Buneman (1997) e considera que um mesmo conteúdo pode mudar de categoria à medida que é tratado.

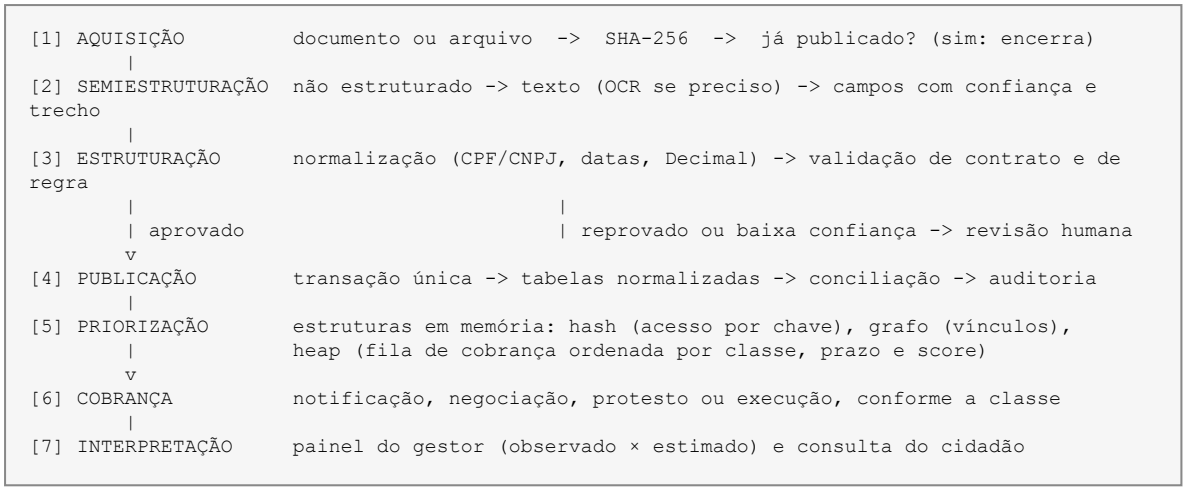
Tabela 1 – Classificação dos dados do pipeline de cobrança

Etapa	Dado	Grau inicial	Origem típica	Passa a estruturado em
Publicação da receita	Arquivo CSV de lançamentos e arrecadação, com contas-pai e componentes	Estruturado com contrato de layout, porém bruto	Portal de transparência da prefeitura	Validação de contrato e publicação em tabelas normalizadas
Cadastro do contribuinte	Sujeito passivo, CPF ou CNPJ, inscrição imobiliária, endereço	Estruturado	Cadastros municipais	Já estruturado; exige normalização e pseudonimização
Lançamento do crédito	Valor principal, multa, juros, vencimento, tributo	Estruturado	Sistema de lançamento	Já estruturado; regra de componentes
Requerimento ou impugnação	Petição, justificativa, anexos	Não estruturado	Protocolo digital ou físico	Extração assistida, com revisão humana
Certidão de dívida ativa	Texto de inscrição, valor, data de inscrição, devedor	Não estruturado (PDF) ou semiestruturado	Sistema de dívida ativa	Extração e validação de campos
Pagamento	Valor, data, código de barras, forma de pagamento	Semiestruturado (arquivo de banco ou API)	Rede bancária ou meio de pagamento	Conciliação com o crédito
Negociação	Parcelas, valor negociado, situação, eventos	Estruturado	Sistema de negociação	Já estruturado; máquina de estados
Descrição de conta	Texto livre que nomeia a receita	Não estruturado	Campo descritivo do portal	Associação ao código da conta, que é a chave

A análise da tabela mostra que o dado mais valioso para a cobrança, o crédito inscrito, nasce quase sempre como registro estruturado, mas as provas que o sustentam, como petições e certidões, permanecem em formato não estruturado. Essa assimetria explica por que a extração assistida é necessária: ela não substitui a base, mas dá acesso às informações que justificam ou contestam o crédito.

4.4 Pipeline algorítmico de ação

O pipeline descreve a sequência de ações do servidor do dado bruto à decisão. Cada etapa tem uma entrada, uma saída e um critério de passagem, o que permite verificar seu funcionamento de forma isolada. A figura 1 resume o fluxo.



A etapa de aquisição garante a idempotência, propriedade que permite reprocessar um arquivo sem duplicar registros. A etapa de publicação é a única em que o dado passa a valer para a gestão, e por isso é tratada como transação atômica. A priorização usa estruturas de dados clássicas: a tabela hash resolve o acesso por identificador em tempo médio constante, o grafo liga sujeito passivo, créditos e imóveis, e a fila de prioridade entrega a próxima ação. Essas estruturas são apenas aceleradoras, porque o estado confiável permanece no banco de dados.

4.5 Onde a cobrança acontece e por qual meio

A cobrança começa quando o tributo lançado não é pago no prazo e o crédito é inscrito em dívida ativa, conforme o Código Tributário Nacional (BRASIL, 1966, art. 201). A partir daí, a cobrança passa por três fronteiras sucessivas. A primeira é administrativa, com notificação e negociação, em que o município ainda depende apenas de seus próprios registros. A segunda é extrajudicial, com protesto da certidão de dívida ativa, admitido pela Lei nº 12.767 (BRASIL, 2012). A terceira é judicial, com execução fiscal regida pela Lei nº 6.830 (BRASIL, 1980), na qual o custo de cada ação precisa ser comparado ao valor recuperável.

O meio de cobrança varia com a fronteira. Na fase administrativa, o contato ocorre por notificação, portal e atendimento presencial. Na fase extrajudicial, o contato passa a ser cartorial. Na fase judicial, a relação é mediada pelo Judiciário. A governança digital atua justamente nas duas primeiras fases, em que a distância entre cidadão e município pode ser reduzida. A fila de prioridade, por sua vez, define quais créditos merecem ser levados a cada fronteira: os de maior valor esperado e menor custo de ação tendem a ser cobrados primeiro, lógica de priorização por valor e risco que a OCDE (2014) associa à gestão da dívida tributária.

4.6 A governança digital na fronteira entre cidadão e município

A governança digital pode diminuir a distância entre cidadão e município por três mecanismos complementares. O primeiro é a unicidade do canal: um login único e uma consulta de situação eliminam o percurso entre setores que, em Dunleavy et al. (2006), caracteriza a administração fragmentada. O segundo é a transparência de estado: cada mudança de situação de um crédito, do lançamento à negociação, fica registrada e pode ser apresentada ao cidadão, o que reduz a assimetria de informação que alimenta a litigiosidade. O terceiro é a previsibilidade: quando a priorização é explícita e reprodutível, o contribuinte entende por que foi acionado e quais critérios se aplicam ao seu caso.

Esses mecanismos só produzem efeito se o dado que os sustenta for confiável. Um painel de situação que exibe um valor errado produz o efeito contrário ao desejado. Por isso, a governança digital depende da qualidade do pipeline descrito acima, e não apenas da interface com o cidadão. Essa dependência é consistente com a constatação de Cabello et al. (2026) de que as práticas tecnológicas da administração tributária local se combinam com outras condições para gerar desempenho.

5 TRANSFORMAÇÃO DE DADOS NÃO ESTRUTURADOS EM ESTRUTURADOS COM INTELIGÊNCIA ARTIFICIAL

5.1 Os quatro estágios

A transformação proposta segue a sequência não estruturado, semiestruturado, estruturado e interpretado. A tabela 2 associa cada estágio à entrada, à saída, à técnica e ao respaldo acadêmico.

Tabela 2 – Estágios de transformação, técnicas e respaldo

Estágio	Entrada	Saída	Técnica	Respaldo
1. Aquisição e normalização	Arquivo bruto (PDF, imagem, CSV)	Texto com identificador único e hash	Hash criptográfico, OCR quando necessário	Vassiliadis (2009); Chu et al. (2016)
2. Semiestruturação	Texto ou layout do documento	Registro com campos, confiança e trecho de origem	Extração por modelo de linguagem com esquema de saída	Xu et al. (2024); Spavound, Schaer e Markou (2026)
3. Estruturação	Campos semiestruturados	Linhas em tabelas normalizadas	Validação de tipo, de contrato e de regra; conciliação	Buneman (1997); Abedjan et al. (2016)
4. Interpretação	Tabelas e estruturas em memória	Decisão, fila e painel	Estruturas de dados (hash, grafo, heap); revisão humana	Gilson, Galster e Georis (2019); Dunleavy et al. (2006)

5.2 Estágio 1: aquisição e normalização

A aquisição começa pelo cálculo de um identificador do conteúdo. Ao aplicar uma função de hash criptográfico ao arquivo inteiro, o sistema sabe se um documento já foi processado e pode evitar reprocessamento e duplicidade, o que é condição para que a carga seja repetível. A normalização converte textos em um formato comum, com codificação uniforme, separadores decimais tratados e identificadores mantidos como texto, para que zeros à esquerda não se percam. Esses cuidados são exigidos pela limpeza de dados, em que a conversão indevida de um código é uma fonte típica de erro (CHU et al., 2016).

5.3 Estágio 2: semiestruturação com modelo de linguagem

A semiestruturação transforma texto livre em registros com campos declarados. O modelo recebe um esquema, com nome, tipo e descrição de cada campo, e deve devolver apenas um objeto que obedeça a esse esquema. Para cada campo, o sistema registra o trecho do documento que o sustenta e um indicador de confiança. Essa exigência de rastreabilidade atende ao princípio de que nenhum dado sem origem verificável deve sustentar um ato de cobrança. Xu et al. (2024) discutem a consistência das saídas geradas como desafio central da extração generativa, o que motiva restringir a saída a um esquema declarado. A separação entre leitura visual e estruturação, descrita por Spavound, Schaer e Markou (2026), permite auditar cada etapa separadamente.

5.4 Estágio 3: estruturação e validação determinística

A saída do modelo nunca é tratada como verdade. Ela passa por regras determinísticas que não dependem de inteligência artificial: o tipo de cada campo, o formato de CPF e CNPJ com verificação de dígitos, a coerência de datas, a aritmética dos valores com precisão decimal exata e a conciliação entre totais e componentes. Abedjan et al. (2016) indicam que diferentes métodos de detecção capturam classes de erro diferentes, o que sustenta combinar regras explícitas com verificações estatísticas. Quando alguma regra falha, ou quando um campo tem confiança abaixo de um limiar, o registro vai para revisão humana e não é publicado. Essa é a aplicação do princípio de que a validação precede a gravação, adotada no estudo de caso.

5.5 Estágio 4: interpretação e decisão

A interpretação combina os dados estruturados com as estruturas de dados em memória para responder às perguntas do gestor. A fila de prioridade ordena as ações de cobrança, o grafo mostra as relações entre sujeito, créditos e imóveis, e a tabela hash dá acesso imediato a qualquer registro. A decisão final permanece com o servidor, e o sistema

apenas registra a recomendação, a versão do critério usado e a ação tomada. Essa separação é coerente com a visão de Dunleavy et al. (2006) de que a administração digital deve ampliar a capacidade de decisão do servidor, sem substituí-la.

5.6 Script automático de referência

O script abaixo apresenta a lógica do estágio 2 e do estágio 3 como pseudocódigo. As funções `llm_extrair`, `ocr_se_necessario`, `enviar_revisao` e `publicar` são ilustrativas e não correspondem a um módulo implementado; a função `validar_contrato` segue a mesma lógica das regras de validação do estudo de caso.

```
def processar_documento(documento):
    sha = sha256(documento)
    if ja_publicado(sha):
        return resumo_registrado(sha)               # idempotência

    texto = ocr_se_necessario(documento)
    campos = llm_extrair(texto, esquema=ESQUEMA)    # JSON com valor, confiança e trecho-fonte

    registro = validar_contrato(campos)             # tipos, CPF/CNPJ, Decimal, obrigatórios
    if registro.erros or min(c.confianca for c in campos) < LIMIAR:
        return enviar_revisao(registro)             # decisão humana, sem publicação

    return publicar(registro)                       # transação única, com auditoria
```

Dois pontos do script merecem destaque. O primeiro é que a validação de contrato é sempre executada, mesmo quando o modelo parece confiável, porque a confiança declarada pelo modelo não é garantia. O segundo é que o script trata o caso de reprocessamento como caminho normal, e não como exceção, o que simplifica a operação quando uma regra é alterada e o documento precisa ser lido de novo.

5.7 Riscos: alucinação, viés e proteção de dados

Três riscos exigem controle explícito. O primeiro é a alucinação, em que o modelo produz um valor plausível sem base no documento; a exigência de trecho-fonte e a validação posterior mitigam esse risco. O segundo é o viés, pois um modelo treinado em documentos de uma região pode falhar em outra, e a amostragem para revisão deve cobrir todos os tipos de documento. O terceiro é a proteção de dados pessoais: CPF e CNPJ são dados pessoais, e a Lei nº 13.709 (BRASIL, 2018) exige finalidade, necessidade e minimização. Por isso, o pipeline substitui identificadores por pseudônimos calculados com HMAC, e os dados que alimentam a extração são limitados ao necessário para a cobrança.

6 ESTUDO DE CASO: O PROJETO INTEGRADOR DE PALMAS-TO

O estudo de caso verifica, sobre um projeto real, a aderência do pipeline às práticas descritas. O projeto organiza o módulo de receita observada em quatro etapas que correspondem ao pipeline: leitura e validação do arquivo do portal, armazenamento com histórico, estruturas em memória e um módulo operacional de créditos e pagamentos. Esse último módulo utiliza dados sintéticos, pois os dados públicos de receita não identificam devedores.

A validação foi aplicada à amostra versionada, com dez linhas reais de IPTU e ISS de janeiro de 2025. Todas as dez linhas foram aceitas, sem erro de contrato. A conciliação entre contas-pai e componentes confirma a aritmética do pipeline: no IPTU, os componentes principal (R$ 2.274.951,38), multas e juros (R$ 100.668,50), dívida ativa (R$ 315.099,43) e dívida ativa com multas (R$ 194.901,33) somam exatamente R$ 2.885.620,64, valor da conta-pai. No ISS, a soma dos quatro componentes, de R$ 21.802.997,01, coincide com a conta-pai. Esse resultado mostra que a regra de não somar o total com os componentes evita a dupla contagem que o trabalho descreve na etapa de validação.

Na situação atual, as etapas de coleta automática, de interpretação pelo cidadão e de extração por inteligência artificial ainda não foram implementadas. A coleta depende de integração segura com a fonte, e a extração de documentos de cobrança depende de acesso a esses documentos, que não fazem parte dos dados públicos disponíveis. Assim, o estudo de caso comprova a camada de validação e de estruturação, mas ainda não comprova o estágio 2 do pipeline.

7 DISCUSSÃO E LIMITAÇÕES

A principal limitação deste trabalho é o respaldo acadêmico em governança digital municipal brasileira. Das publicações verificadas, poucas tratam diretamente da cobrança municipal com dados de nível de contribuinte, e a maior parte aborda a arrecadação agregada. Essa lacuna impede afirmar com precisão quanto da cobrança pode ser recuperado por meio de digitalização, e exige cautela ao generalizar os resultados de Cabello et al. (2026) e de Castro e Afonso (2017) para outros municípios.

Uma segunda limitação é que a validação do estudo de caso foi feita sobre dez linhas, o que demonstra a lógica das regras, mas não sua robustez estatística. A avaliação completa exige o arquivo integral de 176.993 linhas, que está disponível localmente, mas não é versionado no repositório, em coerência com a regra de não versionar base completa.

Além disso, a extração por modelo de linguagem não foi avaliada empiricamente, e sua taxa de acerto em documentos reais de cobrança permanece desconhecida.

Uma terceira limitação é o uso de dados sintéticos no módulo operacional. As relações entre sujeito, crédito e imóvel, bem como a fila de cobrança, foram testadas com dados gerados para esse fim, e não com dados reais de devedores. Os resultados sobre priorização, portanto, mostram a corretude da estrutura, e não a eficácia da cobrança.

8 CONCLUSÃO

Este artigo mostrou que a cobrança tributária municipal pode ser descrita como um pipeline de dados em que cada etapa tem um grau de estruturação, uma entrada e uma saída verificáveis. A partir de oito histórias de usuário do servidor, foi possível classificar os dados do percurso e identificar que as provas da cobrança, como petições e certidões, permanecem não estruturadas, o que justifica a extração assistida por inteligência artificial.

A contribuição principal é a demonstração de que essa extração só é confiável quando inserida em um fluxo com validação determinística, conciliação entre totais e componentes, rastreabilidade de cada campo e revisão humana proporcional ao risco. A literatura com DOI sustenta cada um desses elementos: a semiestruturação de Buneman (1997), o processo de ETL de Vassiliadis (2009), a limpeza de dados de Chu et al. (2016) e Abedjan et al. (2016), e a extração generativa de Xu et al. (2024). Na governança digital, Dunleavy et al. (2006) e Cabello et al. (2026) indicam que o ganho de aproximação entre cidadão e município depende da integração entre canal, transparência e qualidade dos dados.

Como trabalhos futuros, sugere-se avaliar a extração com modelos de linguagem sobre um conjunto rotulado de documentos de cobrança, medindo precisão por campo e a fração de registros que exigem revisão; implementar a integração segura com a fonte de receita; e testar a priorização da fila com dados reais de créditos, sob autorização do município e em conformidade com a legislação de proteção de dados.

REFERÊNCIAS

As referências com DOI foram conferidas pelo serviço de resolução (doi.org) e pelos metadados da Crossref ou da editora. As normas sem DOI são citadas apenas como contexto legal e não como respaldo acadêmico.

Publicações científicas com DOI

ABEDJAN, Ziawasch et al. Detecting data errors: where are we and what needs to be done? *Proceedings of the VLDB Endowment*, v. 9, p. 993–1004, 2016. DOI: 10.14778/2994509.2994518.

AMNA, Anis R.; POELS, Geert. Systematic literature mapping of user story research. *IEEE Access*, v. 10, p. 51723–51746, 2022. DOI: 10.1109/access.2022.3173745.

BUNEMAN, Peter. Semistructured data. In: *Proceedings of the Sixteenth ACM SIGACT-SIGMOD-SIGART Symposium on Principles of Database Systems*, 1997. DOI: 10.1145/263661.263675.

CABELLO, Otávio Gomes et al. Innovation and efficiency in local tax administration: evidence from Brazil. *Revista de Administração Pública*, v. 60, 2026. DOI: 10.1590/0034-761220260007x.

CASTRO, Kleber Pacheco de; AFONSO, José Roberto Rodrigues. IPTU: avaliação de potencial e utilização sob a ótica da teoria dos conjuntos fuzzy. *Revista de Administração Pública*, v. 51, n. 5, 2017. DOI: 10.1590/0034-7612160295.

CHU, Xu et al. Data cleaning: overview and emerging challenges. In: *Proceedings of the 2016 International Conference on Management of Data (SIGMOD)*, 2016. DOI: 10.1145/2882903.2912574.

DUNLEAVY, Patrick; MARGETTS, Helen; BASTOW, Simon; TINKLER, Jane. New public management is dead: long live digital-era governance. *Journal of Public Administration Research and Theory*, v. 16, n. 3, p. 467–494, 2006. DOI: 10.1093/jopart/mui057.

GILSON, Fabian; GALSTER, Matthias; GEORIS, François. Extracting quality attributes from user stories for early architecture decision making. In: *2019 IEEE International Conference on Software Architecture Companion (ICSA-C)*, 2019. DOI: 10.1109/icsa-c.2019.00031.

SPAVOUND, Simon; SCHAER, Oliver; MARKOU, Panos. Tutorial: extracting unstructured text using large language models. *INFORMS Journal on Applied Analytics*, 2026. DOI: 10.1287/inte.2026.0314.

VASSILIADIS, Panos. A survey of extract–transform–load technology. *International Journal of Data Warehousing and Mining*, v. 5, n. 3, p. 1–27, 2009. DOI: 10.4018/jdwm.2009070101.

XU, Derong et al. Large language models for generative information extraction: a survey. *Frontiers of Computer Science*, v. 18, n. 6, 2024. DOI: 10.1007/s11704-024-40555-y.

Relatórios e manuais com DOI

HUTTON, Eric. *The Revenue Administration–Gap Analysis Program: model and methodology for value-added tax gap estimation*. Washington: International Monetary Fund, 2017 (IMF Technical Notes and Manuals). DOI: 10.5089/9781475583618.005.

OECD. *Working smarter in tax debt management*. Paris: OECD Publishing, 2014. DOI: 10.1787/9789264223257-en.

Normas e legislação (sem DOI, usadas como contexto legal)

BRASIL. Lei nº 5.172, de 25 de outubro de 1966. Código Tributário Nacional. Brasília, DF, 1966.

BRASIL. Lei nº 6.830, de 22 de setembro de 1980. Dispõe sobre a cobrança judicial da dívida ativa da Fazenda Pública. Brasília, DF, 1980.

BRASIL. Lei nº 12.767, de 27 de dezembro de 2012. Brasília, DF, 2012.

BRASIL. Lei nº 13.709, de 14 de agosto de 2018. Lei Geral de Proteção de Dados Pessoais (LGPD). Brasília, DF, 2018.