Arquitetura de software para vinculação documental por CPF

Implementação de referência, quatro argumentos favoráveis e quatro críticas fundamentadas

1. Decisão arquitetural e escopo de implantação

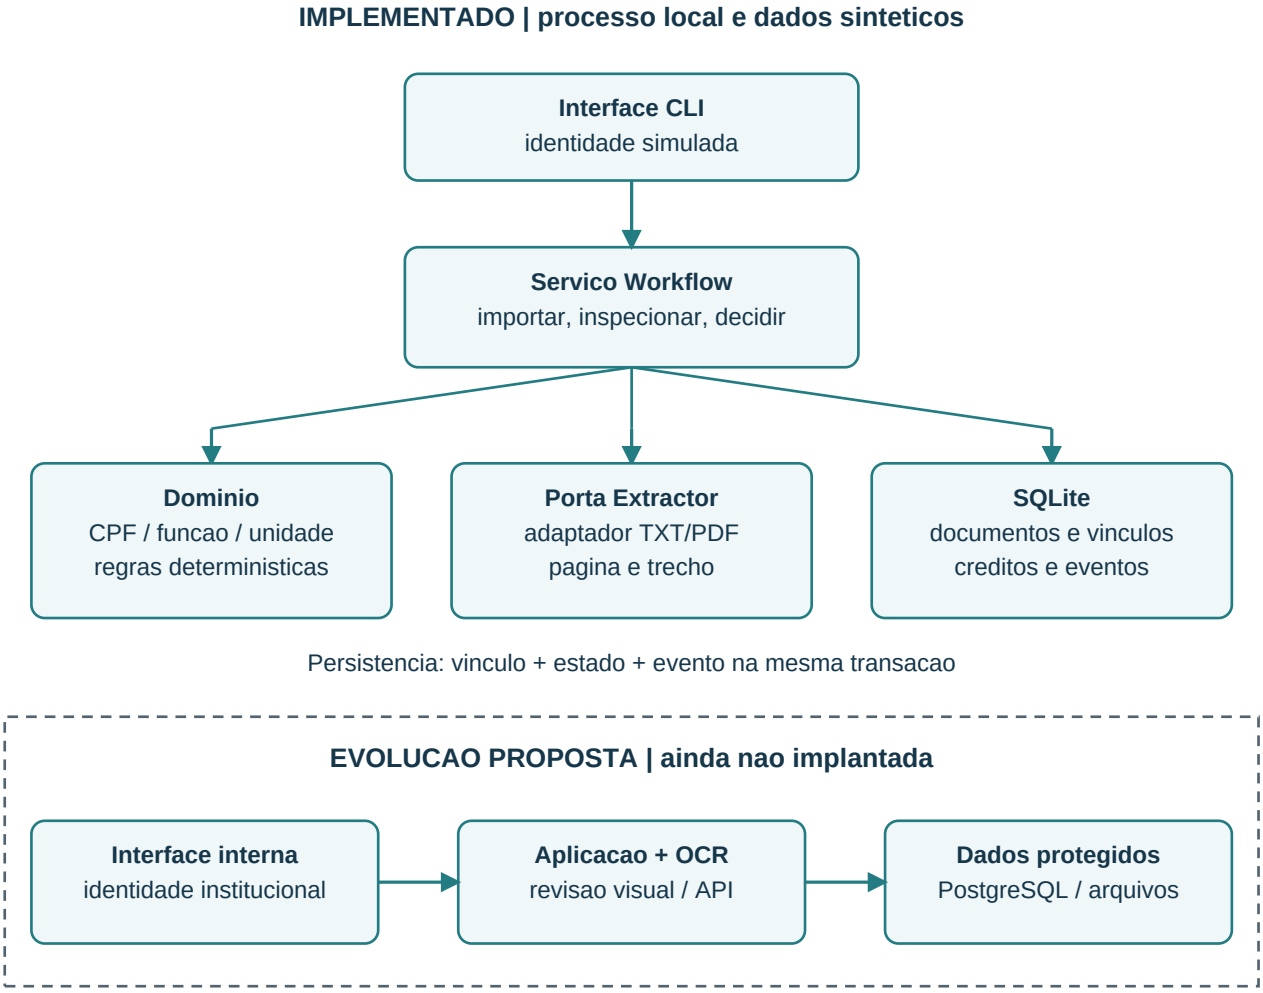
A implantação inicial deve adotar um monólito modular com revisão humana obrigatória, porque o problema prioritário é controlar o vínculo entre documento, contribuinte e crédito. A HU-04 do documento de histórias, na página 7, estabelece a extração revisável; a opção D do Projeto Integrador, nas páginas 10 a 12, situa essa atividade no sistema de inteligência tributária. Parnas (1972) fundamenta a decomposição por responsabilidades que ocultam decisões sujeitas a mudança. A aplicação desse princípio neste trabalho separa regras de CPF, extração, casos de uso, persistência e interface, preservando uma unidade simples de execução para a demonstração acadêmica.

A arquitetura entregue materializa o núcleo de controle e mantém explícitas as integrações ainda ausentes. O pacote arquitetura_cpf implementa importação de TXT e PDF textual, identificação de ocorrências, validação de dígitos, revisão, vínculo com crédito fictício e registro de eventos. A separação entre extração, transformação e carga encontra fundamento em Vassiliadis (2009); neste MVP, ela é aplicada em módulos Python e em transações SQLite. Não há OCR de imagens, autenticação institucional ou acesso à base de Palmas implementados. Portanto, a entrega demonstra a arquitetura do fluxo e suas invariantes, enquanto a operação municipal depende da conclusão dessas integrações e de avaliação no domínio real.

A escolha do monólito é uma decisão contextual, e não uma alegação de superioridade universal. Dragoni et al. (2017) discutem benefícios e desafios dos microsserviços, incluindo a evolução e a distribuição de componentes. Considerando o escopo acadêmico, propõe-se iniciar com um processo e um banco, sem assumir desde já o custo de coordenar serviços distribuídos. O extrator possui uma interface substituível, mas o serviço de aplicação ainda utiliza SQL do adaptador SQLite: a persistência não está completamente desacoplada. Essa limitação é documentada para que uma futura migração de banco seja tratada como trabalho de engenharia, e não como troca automática de configuração.

O resultado esperado da implantação é um processo de identificação documental mais verificável, e sua eficácia deve ser medida antes de ampliar o uso. Fellegi e Sunter (1969) sustentam a distinção entre correspondência de registros e casos inconclusivos, enquanto Mitchell et al. (2019) defendem a explicitação das condições de avaliação dos modelos. Com base nesses fundamentos, o projeto deverá medir erros de associação, esforço de revisão e desempenho por tipo de documento. Redução de inadimplência, comprovação de identidade e detecção conclusiva de fraude não são resultados demonstrados pelo protótipo.

2. Componentes, dependências e fronteira de implantação



A divisão dos componentes deve preservar as regras de negócio mesmo quando a tecnologia de leitura mudar. O diagrama distingue o núcleo executável da evolução proposta: a interface chama o serviço, o serviço combina regras e extração, e o armazenamento mantém documentos, candidatos, créditos, vínculos e eventos. Essa organização aplica o princípio de modularização de Parnas (1972). A porta Extractor aceita outro adaptador, mas qualquer OCR futuro deverá preservar o contrato de evidência e não poderá aprovar vínculos por conta própria.

A infraestrutura de produção deve acrescentar controles que o demonstrador local não oferece. Propõe-se uma interface interna com autenticação institucional, autorização por função e escopo do processo, banco transacional e armazenamento documental protegido. Sandhu et al. (1996) fundamentam permissões por papéis, e Buneman e Tan (2007) fundamentam a rastreabilidade da informação. A escolha de PostgreSQL e armazenamento de objetos para essa evolução é uma decisão de projeto; tais componentes não foram implantados nesta entrega.

3. Quatro argumentos favoráveis à implantação

A1. A modularidade favorece a manutenção porque restringe o impacto de mudanças na tecnologia de extração. Parnas (1972) relaciona a decomposição dos sistemas à flexibilidade e à compreensão do software; neste projeto, esse fundamento orienta a separação entre o contrato Extractor e as regras determinísticas de CPF. Um futuro mecanismo OCR poderá ser incorporado sem deslocar para ele a decisão de vinculação. O benefício esperado é reduzir o retrabalho na evolução do leitor, mas essa economia ainda precisa ser medida. A evidência de implementação é a existência de módulos separados e de uma porta tipada para a extração.

A2. A validação anterior ao vínculo pode reduzir a propagação de erros para os processos tributários. Abedjan et al. (2016) mostram que classes distintas de falhas demandam mecanismos complementares; por isso, a implementação combina consistência dos dígitos, pertencimento do candidato ao documento, compatibilidade entre CPF e crédito e conferência explícita do titular. A extração correta de um número não é aceita como prova suficiente da associação. Os testes demonstram o bloqueio de candidatos inconsistentes e de créditos incompatíveis. O argumento justifica testar a implantação assistida, mas não autoriza prometer ausência de erros de cadastro ou de interpretação humana.

A3. A trilha de decisão favorece a auditabilidade porque preserva a relação entre evidência e ação administrativa. Buneman e Tan (2007) associam proveniência à confiança nos dados; em aplicação desse princípio, o protótipo registra origem, versões do extrator e das regras, revisor, justificativa e instante da decisão. Vínculo, mudança de estado e evento são gravados na mesma transação, de modo que uma falha de auditoria impeça a confirmação parcial. O teste de falha induzida verificou esse comportamento. O ganho proposto é permitir a reconstrução do processo, e não transformar um evento gravado em garantia automática de legitimidade do ato.

A4. A separação de permissões favorece uma implantação controlada porque diferencia consulta, revisão e escopo administrativo. Sandhu et al. (1996) apresentam modelos de controle de acesso por papéis; a adaptação implementada permite consulta ao auditor e decisão ao revisor, sempre na unidade correspondente. Os testes verificaram a rejeição de leitura entre unidades e de escrita pelo auditor. Esse desenho fornece uma base verificável para evoluir o sistema, embora os atores da linha de comando sejam simulados. A implantação real dependerá de identidade autenticada e de regras de acesso ao processo específico, pois função e unidade, isoladamente, podem conceder acesso excessivo.

4. Quatro críticas possíveis e respostas arquiteturais

C1. Um CPF com dígitos consistentes pode produzir vínculo incorreto, portanto a arquitetura não resolve integralmente o problema de identificação. Fellegi e Sunter (1969) tratam a vinculação como decisão sujeita a incerteza, e Li et al. (2023) apresentam reconhecimento textual como tarefa avaliada empiricamente. O documento pode conter identificador de procurador, de terceiro ou de outro crédito, mesmo sem erro aritmético. A resposta proposta é preservar todas as ocorrências, exigir a escolha do candidato e conferir titular e crédito antes da aprovação. O risco residual é a confirmação humana equivocada; a métrica decisiva será a proporção de vínculos incorretos após revisão, e não apenas o acerto dos caracteres.

C2. A revisão humana pode tornar-se confirmação mecânica da sugestão automática e, por isso, não deve ser apresentada como proteção infalível. Parasuraman e Manzey (2010) analisam complacência e viés no uso da automação, incluindo erros de omissão e de aceitação de recomendações imperfeitas. A mitigação proposta combina exibição da evidência original, justificativa, ausência de aprovação automática e auditoria amostral independente. No código entregue, há confirmação explícita e justificativa, mas ainda falta uma interface visual e a avaliação do comportamento dos revisores. O teste futuro deverá comparar a taxa de erro final e o tempo de conferência com o procedimento manual.

C3. A centralização de documentos e identificadores aumenta as consequências de um acesso indevido, mesmo quando há controle por função. Sweeney (2002) mostra que combinações de atributos podem permitir reidentificação; assim, remover o CPF da tela pública não equivale a eliminar o risco. No demonstrador, arquivos e identificadores permanecem em texto claro no SQLite, o que limita seu uso a dados sintéticos. Para a operação institucional, propõem-se armazenamento protegido, gestão de chaves, minimização das cópias, retenção definida e autorização por registro. Essas medidas ainda não foram implementadas e não garantem anonimato; a análise de risco deverá abranger também cópias de segurança e acesso administrativo.

C4. O monólito pode concentrar gargalos e custos de manutenção, sobretudo quando o OCR exigir mais recursos que a revisão. Dragoni et al. (2017) discutem limitações de escalabilidade e diferenças de demanda entre módulos monolíticos. A resposta proposta é medir tamanho da fila, latência e consumo por etapa antes de separar o extrator em um trabalhador independente. Essa evolução exigirá controle de tentativas, deduplicação e tratamento de falhas distribuídas. O MVP atual é síncrono e não comprova desempenho sob carga. Portanto, a implantação deverá considerar capacidade de revisão e custo por documento, evitando que a automação apenas transfira o acúmulo de trabalho para outra etapa.

5. Plano de implantação e critérios de continuidade

A primeira etapa de implantação deve permanecer no ambiente acadêmico com documentos artificiais e cadastro fictício. Essa decisão adapta a preocupação de Sweeney (2002) com exposição e reidentificação às limitações do protótipo. O pacote pode ser executado localmente em Python, e a demonstração percorre importação, inspeção e decisão sobre um crédito sintético. Não é necessário publicar um serviço nem conectar a Receita Federal para comprovar as invariantes dessa etapa. A leitura de PDF textual foi exercitada, mas o papel do titular é conferido manualmente e páginas sem texto são encaminhadas ao estado OCR_REQUIRED, sem reconhecimento de imagem executado.

A segunda etapa deve funcionar em modo de observação, com resultados comparados ao procedimento vigente e sem produzir atos de cobrança. Mitchell et al. (2019) fundamentam a documentação de uso pretendido e desempenho por condições relevantes; para este projeto, propõe-se um conjunto autorizado e rotulado, separado do desenvolvimento, com diferentes layouts e qualidades de captura. A instituição deverá definir previamente a tolerância a vínculos incorretos e os limites de esforço de revisão. Devem ser apresentados intervalos de incerteza, tamanho da amostra e resultados por condição; ausência de erro em poucos exemplos não será interpretada como garantia universal.

A terceira etapa deve liberar apenas a vinculação documental assistida após a validação funcional, operacional e de acesso. O controle por papéis descrito por Sandhu et al. (1996) fornece fundamento para a autorização, mas a implantação proposta acrescenta autenticação institucional e restrição por processo. O serviço ficará em rede interna, os documentos terão armazenamento protegido e as mudanças de banco terão migrações versionadas, cópia de segurança e ensaio de restauração. O escopo inicial continuará limitado à HU-04; negociação, consulta do cidadão e priorização da cobrança exigirão integrações e avaliações próprias. Essas condições são requisitos de implantação, não recursos já disponíveis no código entregue.

A continuidade da implantação deve depender de evidência operacional e de capacidade de reversão. Buneman e Tan (2007) sustentam a importância de rastrear a origem dos dados; em aplicação desse fundamento, cada versão deverá manter resultados identificáveis e permitir localizar vínculos potencialmente afetados. Propõe-se interromper novas confirmações diante de associação indevida recorrente, falha de acesso ou degradação relevante, preservando o histórico e retomando a conferência manual. Antes do uso real, será necessário implementar revogação e correção rastreáveis, pois o MVP tem estados terminais sem reabertura. Custos de OCR, infraestrutura e revisão deverão ser comparados ao tempo economizado para fundamentar a decisão de expansão.

6. Contratos implementados, testes e conclusão

O contrato de importação deve conservar a evidência e distinguir repetição de arquivo de uma nova avaliação. Vassiliadis (2009) fundamenta a organização das etapas de transformação; no protótipo, o registro usa unidade, resumo SHA-256 e versões do extrator e das regras para evitar duplicação da mesma avaliação. O arquivo original é preservado como BLOB, e cada ocorrência contém CPF textual, página, posição inicial e final na string extraída e trecho de contexto. Essas posições não são coordenadas visuais. A extração é síncrona e ocorre antes da consulta de duplicidade, de modo que a gravação é idempotente, mas o custo de leitura pode se repetir.

O contrato de decisão deve bloquear a aprovação quando os requisitos do vínculo não estiverem satisfeitos. A distinção entre evidência e correspondência discutida por Fellegi e Sunter (1969) fundamenta essa separação; a aplicação concreta exige estado REVIEW, candidato do mesmo documento, dígitos consistentes, CPF compatível com o crédito, mesma unidade, confirmação do titular, justificativa e versão atual. A gravação aceita um vínculo por documento neste MVP. Documentos sem CPF ou sem texto podem ser rejeitados, mas não aprovados; solicitações com múltiplos créditos, correção de papéis e reabertura de decisões exigem extensão do esquema e do fluxo.

Os testes confirmam propriedades específicas do protótipo e não medem acurácia de OCR ou resultado fiscal. Foram executados 13 testes automatizados, todos aprovados, cobrindo consistência dos dígitos, evidência, duplicidade por unidade, múltiplas ocorrências, bloqueio de acesso, incompatibilidade de crédito, candidato de outro documento, decisão desatualizada, reversão da transação quando falha a auditoria, ausência de texto, rejeição e PDF textual. A linha de comando também percorreu importação, inspeção e aprovação em banco temporário. Essa delimitação segue a preocupação de Mitchell et al. (2019) com a comunicação das condições de avaliação; nenhum motor OCR foi treinado ou avaliado nesta entrega.

A implantação é justificável como evolução controlada do atendimento documental, desde que seus limites permaneçam verificáveis. Os argumentos de modularidade, qualidade, auditoria e autorização sustentam a adoção experimental, enquanto as críticas de vínculo incorreto, viés de automação, exposição de dados e custo operacional impedem uma liberação irrestrita. Parnas (1972) fundamenta a divisão de responsabilidades, e Parasuraman e Manzey (2010) mostram por que a participação humana também precisa ser avaliada. A recomendação final é implantar o demonstrador acadêmico agora e condicionar a operação municipal às integrações, aos controles de segurança e às evidências de desempenho descritos neste documento.

Referências acadêmicas

ABEDJAN, Ziawasch et al. Detecting data errors: where are we and what needs to be done? Proceedings of the VLDB Endowment, v. 9, n. 12, p. 993-1004, 2016.
DOI: 10.14778/2994509.2994518.

BUNEMAN, Peter; TAN, Wang-Chiew. Provenance in databases. In: Proceedings of the 2007 ACM SIGMOD International Conference on Management of Data. New York: ACM, 2007. p. 1171-1173.
DOI: 10.1145/1247480.1247646.

DRAGONI, Nicola et al. Microservices: yesterday, today, and tomorrow. In: Present and Ulterior Software Engineering. Cham: Springer, 2017. p. 195-216.
DOI: 10.1007/978-3-319-67425-4_12.

FELLEGI, Ivan P.; SUNTER, Alan B. A theory for record linkage. Journal of the American Statistical Association, v. 64, n. 328, p. 1183-1210, 1969.
DOI: 10.1080/01621459.1969.10501049.

LI, Minghao et al. TrOCR: Transformer-based optical character recognition with pre-trained models. Proceedings of the AAAI Conference on Artificial Intelligence, v. 37, n. 11, p. 13094-13102, 2023.
DOI: 10.1609/aaai.v37i11.26538.

MITCHELL, Margaret et al. Model cards for model reporting. In: Proceedings of the Conference on Fairness, Accountability, and Transparency. New York: ACM, 2019. p. 220-229.
DOI: 10.1145/3287560.3287596.

Referências acadêmicas (continuação)

PARASURAMAN, Raja; MANZEY, Dietrich H. Complacency and bias in human use of automation: an attentional integration. Human Factors, v. 52, n. 3, p. 381-410, 2010.
DOI: 10.1177/0018720810376055.

PARNAS, David L. On the criteria to be used in decomposing systems into modules. Communications of the ACM, v. 15, n. 12, p. 1053-1058, 1972.
DOI: 10.1145/361598.361623.

SANDHU, Ravi S.; COYNE, Edward J.; FEINSTEIN, Hal L.; YOUMAN, Charles E. Role-based access control models. Computer, v. 29, n. 2, p. 38-47, 1996.
DOI: 10.1109/2.485845.

SWEENEY, Latanya. k-anonymity: a model for protecting privacy. International Journal of Uncertainty, Fuzziness and Knowledge-Based Systems, v. 10, n. 5, p. 557-570, 2002.
DOI: 10.1142/S0218488502001648.

VASSILIADIS, Panos. A survey of extract-transform-load technology. International Journal of Data Warehousing and Mining, v. 5, n. 3, p. 1-27, 2009.
DOI: 10.4018/jdwm.2009070101.

Método e fontes do contexto

A fundamentação resulta de consulta dirigida a artigos, capítulo acadêmico, textos de autores e registros editoriais, sem pretensão de revisão sistemática. A literatura respalda princípios; a seleção de componentes, as etapas de implantação e os critérios propostos são decisões deste projeto. O código foi testado com fixtures sintéticas, e os resultados não constituem validação de OCR, segurança de produção ou eficácia tributária. Fontes consultadas em 21 out. 2026.

Contexto documental: Projeto Integrador - Eixo II (UFT, 2026), especialmente p. 10-17; Histórias de usuário e transformação de dados para a cobrança tributária municipal (equipe PI2, 2026), p. 7 e 13-14; Relatório técnico de identificação e validação do CPF com IA (2026), 2 p. Os três arquivos foram fornecidos pelo usuário. Esta arquitetura dá continuidade ao relatório de utilidade elaborado a partir desses materiais.